


2026 届研究生硕士学位论文

分类号: \_\_\_\_\_

学校代码: 10269

密 级: \_\_\_\_\_

学 号: 51264404067



華東師範大學

East China Normal University

硕士学位论文

MASTER'S DISSERTATION

# 基于可解释性机器学习和保形预测的 航班进近阶段乱流指数强度分析

院 系: 统计学院

专业学位类别: 应用统计硕士

专业学位领域: 应用统计

学位申请人: 徐宇航

指 导 教 师: 钟琰

2026 年 5 月



Dissertation for Master's Degree in 2026

University Code: 10269

Student ID: 51264404067

EAST CHINA NORMAL UNIVERSITY

# **Analysis of Turbulence Intensity Index during Aircraft Approach Phase Based on Interpretable Machine Learning and Conformal Prediction**

|                     |                              |
|---------------------|------------------------------|
| Department:         | School of Statistics         |
| Major:              | Master of Applied Statistics |
| Research Direction: | Applied Statistics           |
| Candidate:          | Yuhang Xu                    |
| Supervisor:         | Yan Zhong                    |

May, 2026



## 华东师范大学学位论文原创性声明

郑重声明：本人呈交的学位论文《基于可解释性机器学习和保形预测航班进近阶段乱流指数强度分析》，是在华东师范大学攻读硕士/博士（请勾选）学位期间，在导师的指导下进行的研究工作及取得的研究成果。除文中已经注明引用的内容外，本论文不包含其他个人已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中作了明确说明并表示谢意。

作者签名：\_\_\_\_\_

日期： 年 月 日

## 华东师范大学学位论文著作权使用声明

《基于可解释性机器学习和保形预测航班进近阶段乱流指数强度分析》系本人在华东师范大学攻读学位期间在导师指导下完成的硕士/博士（请勾选）学位论文，本论文的研究成果归华东师范大学所有。本人同意华东师范大学根据相关规定保留和使用此学位论文，并向主管部门和相关机构如国家图书馆、中信所和“知网”送交学位论文的印刷版和电子版；允许学位论文进入华东师范大学图书馆及数据库被查阅、借阅；同意学校将学位论文加入全国博士、硕士学位论文共建单位数据库进行检索，将学位论文的标题和摘要汇编出版，采用影印、缩印或者其它方式合理复制学位论文。

本学位论文属于（请勾选）

☐ 1. 经华东师范大学相关部门审查核定的“内部”或“涉密”学位论文\*，于 年 月 日解密，解密后适用上述授权。

☐ 2. 不保密，适用上述授权。

导师签名：\_\_\_\_\_

本人签名：\_\_\_\_\_

年 月 日

\* “涉密”学位论文应是已经华东师范大学学位评定委员会办公室或保密委员会审定过的学位论文（需附获批的《华东师范大学研究生申请学位论文“涉密”审批表》方为有效），未经上述部门审定的学位论文均为公开学位论文。此声明栏不填写的，默认为公开学位论文，均适用上述授权）。



xxx 硕士学位论文答辩委员会成员名单

| 姓名 | 职称 | 单位 | 备注 |
|----|----|----|----|
|    |    |    | 主席 |
|    |    |    |    |
|    |    |    |    |
|    |    |    |    |
|    |    |    |    |



## 摘 要

在航空运营中，进近阶段因飞行高度低、速度慢、操纵敏感，极易受到气流扰动的影响，是飞行安全的关键窗口。近年来，快速存取记录器（QAR）数据因其高频率、高精度的飞行参数记录，已被广泛用于进近阶段风场风险的识别。然而，当前研究虽已初步建立了风场变化与飞行员操作响应之间的关联，但仍然存在精度不足，难以量化风场影响的不确定性等问题。

本文基于真实航班的 QAR 数据，旨在构建一套科学、可量化的评价指标体系，用于评估进近阶段低空乱流对飞行员操作行为的实际影响，一方面引入可解释性机器学习，确保指标生成过程透明、结果可追溯；另一方面融合不确定性量化，实现对风险水平及其置信边界的协同刻画。具体而言，首先设计一种双分支神经网络结构，将高度相关因素与风场变量的影响进行解耦建模，从而提取出能够真实反映风场扰动所引发飞行员操作响应的核心指标，并通过实证验证其有效性。其次，为满足实际运行中对模型透明度与可解释性的需求，在对部分关键变量进行针对性预处理的基础上，结合 SHAP(Shapley Additive Explanations) 方法，对风场特征的高阶交互效应进行筛选，进而构建以所提指标为因变量、原始及衍生风场特征为自变量的回归模型。该模型在保持优异预测性能的同时（Spearman 相关系数较现有方法提升 50%），显著增强了可解释性。再次，针对运行场景中对不确定性量化的需求，引入保形预测（Conformal Prediction）方法，为所构建的乱流指数提供具有有限样本统计保证的预测区间，实现对模型不确定性的精准刻画（预测区间覆盖率可达 90%）。

最后，从机场实际运行视角出发，按时间窗口对历史航班数据进行聚合分析，构建随时段动态调整的乱流指数警戒阈值，并开展相关实证分析。本研究为进近阶段风扰风险的实时监控与预警提供了兼具准确性、可解释性与统计可靠性的技术方案，有望融入民航飞行品质监控与机场运行安全评估体系。

**关键词：**QAR 数据、乱流指数、双支神经网络、SHAP 可解释性分析、保形预测

## ABSTRACT

In aviation operations, the approach phase is a critical window for flight safety due to low altitude, slow speed, and high control sensitivity, making it highly susceptible to airflow disturbances. In recent years, Quick Access Recorder (QAR) data, characterized by high-frequency and high-precision flight parameter recording, has been widely used for identifying wind field risks during the approach phase. However, although current research has preliminarily established the correlation between wind field variations and pilot control responses, it still suffers from insufficient accuracy and the difficulty in quantifying the uncertainty of wind field impacts.

Based on real-flight QAR data, this paper aims to construct a scientific and quantifiable evaluation index system to assess the actual impact of low-altitude turbulence on pilot behavior during the approach phase. This study introduces interpretable machine learning to ensure transparency and traceability of the index generation process, while integrating uncertainty quantification to jointly characterize risk levels and their confidence boundaries. Specifically, a dual-branch neural network structure is first designed to decouple the effects of highly correlated factors from wind field variables, thereby extracting core indicators that truly reflect pilot control responses induced by wind disturbances, and validating their effectiveness through empirical analysis. Secondly, to meet the transparency and interpretability requirements of actual operations, and based on targeted preprocessing of key variables, the SHAP (Shapley Additive Explanations) method is combined to screen for high-order interaction effects of wind field features. A regression model is then constructed using the proposed indicators as the dependent variable and original as well as derived wind field features as independent variables. While maintaining superior predictive performance (the Spearman correlation coefficient is improved by 50% compared to existing methods), the model significantly enhances interpretability. Furthermore, addressing the need for uncertainty quantification in operational scenarios, the Conformal

Prediction method is introduced to provide prediction intervals with finite sample statistical guarantees for the constructed turbulence index, achieving precise characterization of model uncertainty (prediction interval coverage reaches 90%).

Finally, from the perspective of actual airport operations, historical flight data is aggregated by time windows to construct dynamically adjusted turbulence index warning thresholds based on time of day, followed by empirical analysis. This research provides a technical solution for real-time monitoring and early warning of wind disturbance risks during the approach phase that combines accuracy, interpretability, and statistical reliability, holding promise for integration into civil aviation flight quality monitoring and airport operational safety assessment systems.

**Keywords:** *QAR data, turbulence index, dual-branch neural network, SHAP interpretability analysis, conformal prediction*

## 目 录

|                           |     |
|---------------------------|-----|
| 摘要 .....                  | i   |
| Abstract .....            | iii |
| 图目录 .....                 | vi  |
| 表目录 .....                 | ix  |
| 第一章 引言 .....              | 1   |
| 1.1 研究背景与意义 .....         | 1   |
| 1.2 国内外研究现状 .....         | 2   |
| 1.2.1 乱流预警相关研究 .....      | 2   |
| 1.2.2 人为因素研究 .....        | 5   |
| 1.2.3 当前研究不足 .....        | 6   |
| 1.3 主要研究内容 .....          | 7   |
| 第二章 QAR 数据预处理与因变量生成 ..... | 11  |
| 2.1 QAR 数据介绍 .....        | 11  |
| 2.2 QAR 数据预处理与特征构建 .....  | 12  |
| 2.2.1 研究样本筛选 .....        | 12  |
| 2.2.2 变量时序对齐与特征工程 .....   | 14  |
| 2.3 响应变量构建 .....          | 17  |
| 第三章 乱流指数构建 .....          | 21  |
| 3.1 基于神经网络的乱流指数构建 .....   | 21  |
| 3.1.1 相关研究 .....          | 21  |
| 3.1.2 神经网络分离高度影响策略 .....  | 22  |
| 3.1.3 模型结果评价 .....        | 24  |

|       |                       |    |
|-------|-----------------------|----|
| 3.2   | 可解释模型的构建 .....        | 28 |
| 3.2.1 | 新响应变量与线性模型 .....      | 28 |
| 3.2.2 | 新变量生成与筛选 .....        | 29 |
| 3.2.3 | 可解释线性模型的构建与模型结果 ..... | 33 |
| 第四章   | 乱流强度区间估计 .....        | 37 |
| 4.1   | 经典区间预测不足 .....        | 37 |
| 4.2   | 保形预测原理 .....          | 38 |
| 4.3   | 实验结果分析 .....          | 40 |
| 第五章   | 机场整体乱流指数分布 .....      | 45 |
| 5.1   | 机场预警研究 .....          | 45 |
| 5.2   | 风险持续性分析 .....         | 47 |
| 第六章   | 总结与展望 .....           | 49 |
| 6.1   | 研究工作总结 .....          | 49 |
| 6.2   | 研究不足与未来展望 .....       | 50 |
| 参考文献  | .....                 | 56 |
| 致谢    | .....                 | 57 |

## 图目录

|       |                                              |    |
|-------|----------------------------------------------|----|
| 图 2.1 | QAR 数据格式示例 .....                             | 12 |
| 图 2.2 | 响应变量与高度的相关性 .....                            | 18 |
| 图 2.3 | 风场复杂度与高度的相关性 .....                           | 18 |
| 图 3.1 | 高度对飞行员操作波动的影响趋势 .....                        | 25 |
| 图 3.2 | 神经网络乱流指数与风场的相关性 .....                        | 26 |
| 图 3.3 | 神经网络乱流指数与飞行员操作的相关性 .....                     | 27 |
| 图 3.4 | WINHEAD_COS 与飞行员俯仰操作 (mean_pitch) 的相关性 ..... | 30 |
| 图 3.5 | WINHEAD_SIN 与飞行员俯仰操作 (mean_pitch) 的相关性 ..... | 31 |
| 图 3.6 | SHA03 某航班乱流指数及风场变化趋势 .....                   | 35 |
| 图 4.1 | 可解释性模型残差的 Q-Q 图 .....                        | 37 |
| 图 4.2 | 线性模型 cqr 部分航班预测区间示例 .....                    | 42 |
| 图 4.3 | 随机森林 local 部分航班预测区间示例 .....                  | 43 |
| 图 4.4 | 线性模型 cqr 分箱下的准确率 .....                       | 43 |
| 图 4.5 | 随机森林 local 分箱下的准确率 .....                     | 44 |
| 图 5.1 | 3 月 A320 航班乱流指数整体分布情况 .....                  | 45 |
| 图 5.2 | 乱流指数预警线示例图 .....                             | 46 |
| 图 5.3 | 虹桥机场 3 月航班乱流指数安全范围 .....                     | 46 |



表目录

表 2.1 原始 QAR 变量说明 ..... 13

表 3.1 风场相关输入变量说明 ..... 23

表 3.2 不同模型对 iqr\_pitch 在测试集上的拟合性能对比 ..... 24

表 3.3 不同方法对风场影响拟合的相关性对比 ..... 28

表 3.4 线性模型在测试集上的性能评价指标 ..... 29

表 3.5 风向航向夹角三角函数值物理意义 ..... 29

表 3.6 参与衍生风场相关特征变量说明 ..... 32

表 3.7 各特征变量的均值与标准差 ..... 34

表 3.8 Lasso 筛选后入模变量分类 ..... 34

表 3.9 不同模型的性能评价指标对比 ..... 35

表 4.1 不同方法与基学习器的平均覆盖率及平均区间宽度对比 ..... 41

表 5.1 3 月 10 日各小时航班状态统计 ..... 47



## 第一章 引言

### 1.1 研究背景与意义

近年来，全球民用航空业展现出强劲的复苏与增长态势，运输规模屡创历史新高。在国际层面，根据国际航空运输协会（International Air Transport Association, IATA）发布的最新数据，2024 年全球商业航空客运量突破 50 亿人次，全年执飞航班总数超过 4060 万架次 [1]。这一数字不仅标志着行业已逐渐走出疫情阴影，也显示出长期需求的持续扩张。在国内层面，我国民航运输生产规模同样实现了跨越式发展，据中国民航局发布的《2024 年民航行业发展统计公报》显示，2024 年全行业完成运输总周转量 1485.2 亿吨公里，旅客运输量达到 7.3 亿人次，同比分别大幅增长 25.0% 和 17.9%，较 2019 年疫情前水平也分别增长了 14.8% 和 10.6% [2]。特别是在国际航线方面，2024 年中国国际客运航班恢复至每周 6400 班，达到疫情前的 84%，国际货邮运输量同比增长 29.3%，凸显了中国航空市场在全球网络中日益增强的核心地位。

伴随着民用航空运输量的持续增长，全球航空安全水平也实现了显著提升，国际民航组织（International Civil Aviation Organization, ICAO）统计数据显示 2023 年事故率已降至历史低位，尽管 2024 年数据有所上升，但仍处于历史较低水平。相关事故数据分析表明，复杂气象条件仍是影响飞行安全的核心因素 [3]。波音公司发布的全球事故统计摘要指出，进近与着陆阶段虽仅占航班总飞行时长的约 5%，却有接近 50% 的致命事故发生在这一阶段；其中，由风切变（Wind Shear）与大气乱流（Turbulence）诱发的不稳定进近被确认为关键原因 [4]。特别是在低空进近阶段，微下击暴流等中小尺度风场现象具有极强的突发性与巨大的空间梯度，受限于时空分辨率，传统地基雷达探测系统往往存在盲区或预警时效滞后，难以实现精准捕捉。在此类极端扰动环境下，飞行员的实时态势感知与操纵决策构成了防止事故发生的最后一道防线。国内基于快速存取记录器（Quick Access Recorder, QAR）数据的实证研究表明，在同等风切变强度下，飞行员操纵响应的延迟或修正过量是导致飞行轨迹偏离甚至引发冲偏出跑道的主要人为因素；此类“人机耦合”

机制失效在复杂气象相关不安全事件中的占比高达 60% [5]。因此，利用高采样率 QAR 数据分析风场环境下的飞行员操纵情况，深入揭示乱流扰动情况，对于提升进近阶段的安全裕度具有重要的理论意义与工程应用价值。

在这种背景下，本文旨在解决以下核心科学问题：如何利用航班的 QAR 数据，构建一个能够关联风场环境扰动与人因响应的量化评价指标，以量化评估风场动态变化对飞行员操纵行为的影响程度。在此基础上，面向实际应用需求，引入不确定性量化分析，并开展机场层面的实证研究。本研究成果不仅有助于理解风扰动下的人机交互特性，还可为飞行员操作决策支持、空中交通管理策略优化以及航空公司风险预警体系的构建提供更加精准、可靠的科学依据，进而推动民航安全管理体系向精细化、智能化和数据驱动方向持续演进。

## 1.2 国内外研究现状

### 1.2.1 乱流预警相关研究

乱流是指大气中局部区域内风速或风向在短时间内发生的剧烈变化。其中，低空风切变（Low-Level Wind Shear, LLWS）特指发生在地面以上 600 米高度范围内的风矢量（包括风速或风向）的急剧变化。此类气象现象不仅与雷暴、锋面系统、低空急流及低空逆温等天气过程密切相关，同时其局地特征也显著受机场周边环境的影响，包括建筑物布局、自然障碍物、地形粗糙度以及水陆交界等地表异质性因素 [6]。目前，针对乱流的监测与预测主要依赖三类数据源：雷达观测、QAR 数据，数值天气预报及多源辅助观测资料。

#### 1) 雷达数据预测

多普勒天气雷达（Doppler Weather Radar, DWR）是一种广泛应用于气象探测的先进风场遥感设备，通过发射特高频电磁波并分析回波的多普勒频移来反演风场结构。该技术在降水条件下表现尤为突出，能够有效监测和预警强对流天气、低空风切变及大气湍流等航空危险气象现象 [7]。相比之下，激光测风雷达（Doppler Light Detection and Ranging, LiDAR）作为新兴的风场探测手段，利用大气中气溶胶粒子对激光的后向散射信号中的多普勒频移推导风速信息，具有体积小、相干性强、测量精度高以及可获取高时空分辨率风场数据等优势 [8]。近年来，LiDAR 技

术在机场风切变监测中展现出显著应用价值。Zhang 等人 [6] 利用脉冲相干多普勒激光雷达 (Pulsed Coherent Doppler LiDAR, PCDL) 对北京首都国际机场 (Beijing Capital International Airport, BCIA) 的低空风切变进行观测, 验证了 PCDL 在捕捉近地面风场突变方面的有效性。Yuan 等人 [9] 基于北京大兴国际机场部署的单台相干多普勒测风激光雷达 (Coherent Doppler Wind Lidar, CDWL), 结合变分方法反演二维风场, 并进一步计算跑道相关风速以评估风切变强度。结果表明该方法不仅能有效识别微下击暴流等多种危险气象事件, 在风切变验证实验中更实现了 100% 的检测概率。此外, Cai 等人 [10] 利用香港天文台 (Hong Kong Observatory, HKO) 的终端多普勒天气雷达 (Terminal Doppler Weather Radar, TDWR) 数据, 建立人工神经网络 (Artificial Neural Network, ANN) 模型用于台风背景下低空湍流的诊断与分类, 其性能显著优于传统的谱宽阈值法。Chan 等人 [11] 则基于香港国际机场 (Hong Kong International Airport, HKIA) 的 LiDAR 观测, 提出一种基于逆风梯度的 F 因子计算方法, 并将其与现有的下滑道扫描风切变警报算法 (GLYGA) 融合, 在特定跑道场景下展现出优于现行警报服务的预警能力。近期, Zhao 等人 [12] 利用西宁曹家堡国际机场的激光雷达数据, 综合采用雷达信号斜率特征、S 因子算法及改进的 F 因子算法对锋面过境期间的风切变过程进行分析, 结果表明三种方法均能有效捕捉风切变波动的整体趋势, 为多算法融合的风切变识别提供了实证依据。

## 2) QAR 数据预测

快速存取记录器 (Quick Access Recorder, QAR) 是一种机载数据记录设备, 能够连续采集并存储航空器在整个运行过程中各类飞行参数的实时变化及其性能状态。这些参数涵盖飞行轨迹、姿态角、操纵输入、发动机状态及外部气象条件等, 能够客观、全面地还原飞行全过程的飞行品质与飞行员操作行为。作为飞行运行品质监控 (Flight Operational Quality Assurance, FOQA) 体系的核心数据源, QAR 不仅为飞行技术检查、风险评估与故障诊断提供关键支撑, 也为不安全事件的深度分析、致因要素探究及风险预测奠定了坚实的数据基础, 是开展飞行安全研究的重要信息载体 [13]。

近年来, 基于 QAR 数据的风场与湍流研究取得了显著进展。Wang 等人 [14] 利用中国民航局 FOQA 系统积累的 QAR 大数据, 对低空风切变预警事件进行统

计分析,揭示了其时空分布特征与关键飞行参数的关联规律,并据此提出运行改进建议。Ito 等人 [15] 从机场视角出发,采用拉普拉斯分布拟合逆风变化率,结合各机场特有的地理与气象环境,开发了乱流风险可视化平台。在乱流强度量化方面, Kim 等人 [16] 基于 1 Hz 采样的 QAR 数据,提出了多种涡旋耗散率 (Eddy Dissipation Rate, EDR) 的估算方法,该方法具备应用于实时 QAR 数据处理的潜力; Huang 等人 [17] 则融合两种传统 EDR 估算模型,设计了一种新流程,相较于基于垂直过载 (vertical overload) 或差分垂直能量梯度 (Differential Vertical Energy Gradient, DVEG) 的方法,能更准确地表征乱流风险。此外, Zhuang 等人 [18] 引入遗传编程驱动的符号分类器,利用 QAR 数据实现乱流异常检测,其检测性能与基于 EDR 直接计算的结果相当,且在跨机场数据上的泛化能力优于其他机器学习方法。Mizuno 等人 [19] 进一步融合日本气象观测与 QAR 数据,通过主成分分析 (PCA) 结合 K-Means 聚类生成风险模式簇,并采用支持向量机 (SVM) 构建乱流发生日期的预测模型,实现了较高精度的短期风险预报。

### 3) 其他数据源预测

除雷达与机载 QAR 数据外,研究者亦广泛探索其他数据源在乱流与风切变预测中的应用潜力,包括数值天气预报 (Numerical Weather Prediction, NWP) 输出、飞行员报告 (Pilot Reports, PIREPs) 以及新型观测平台。这些方法通过融合气象模型、运行事件记录或现场观测数据,从不同维度提升对大气扰动的感知与预判能力。

Hon 等人 [20] 利用香港天文台区域 NWP 模型的输出数据,构建了基于 XG-Boost 算法的多指数共识 (Multi-Index Consensus, MIC) 模型,用于航空乱流预测,并在超过 16,000 份飞行员报告上进行了验证,结果表明其性能优于传统单一指数方法。Khattak 等人 [21] 采用二元逻辑回归模型 (Binary Logistic Regression Model), 结合 L1 与 L2 正则化技术,对 2015 至 2023 年间香港国际机场的飞行员报告数据进行分析,识别出影响风切变相关复飞事件的关键气象与运行因素,并据此提出针对性的运行建议。Kim 等人 [22] 则利用高分辨率的天气研究与预报模式 (Weather Research and Forecasting Model, WRF), 计算多种乱流诊断指标并将其统一映射至 EDR 指标,在多指标融合的基础上开展湍流预测,并将结果应用于空中交通管理

(Air Traffic Management, ATM) 中的航路规划与风险规避。此外, Haghghi 等人 [23] 通过气球释放的小型无人航空系统 (balloon-launched small uncrewed aircraft system) 对对流层及平流层下部的乱流进行原位观测, 验证了该平台在高空气象参数测量中的可行性与有效性。

### 1.2.2 人为因素研究

国际民用航空组织 (International Civil Aviation Organization, ICAO) 将人为因素定义为“关于人的生活和工作条件, 关于人与机器、程序及环境之间的关系, 以及人在工作中与其他人的互动”。研究表明, 约 75% 的航空事故与事故征候可归因于人为因素 [24]。尽管人为因素的主导地位已在业界形成共识, 但仅凭定性的概念定义尚不足以指导具体的安全干预措施。为了将抽象的“人为因素”转化为可量化的风险指标, 并精准识别出事故高发的特定运行场景与关键原因, 学术界与工业界亟需基于长周期、大样本的历史数据进行深入的统计实证分析。正是在这一背景下, 针对商业航空运输事故数据的系统性量化研究显得尤为关键, 旨在通过数据挖掘揭示隐藏在不同航班属性背后的人为失误规律。

Kharoufah 等人 [24] 基于 2000 至 2016 年间 200 余起商业航空运输事故与事故征候数据, 按航班属性 (包括日期、制造商、承运人、运行阶段等) 进行编码, 并采用卡方检验分析各分类变量对事故发生的统计显著性。GUO 等人 [25] 则基于过去 43 年民用航空致命事故的调查报告, 提取出 20 个常见风险因素 (如飞行员误判、空中交通管制失误、安全检查疏漏、极端天气等), 并通过关联规则挖掘其隐形耦合关系, 进一步筛选出 6 个关键因素; 在此基础上, 结合深度学习方法, 有效识别事故演化过程中可能发生的事故类型。Chen 等人 [26] 运用层次任务分析 (Hierarchical Task Analysis, HTA) 方法梳理通用航空进近着陆阶段的操作逻辑与流程, 并基于 SHELL 模型从软件 (Software)、硬件 (Hardware)、环境 (Environment)、人员 (Liveware) 四个维度系统识别潜在危害, 针对进近着陆阶段典型的人为与环境风险提出改进建议。然而, 上述研究多依赖已发生的事故数据, 样本量有限, 难以支撑对常态运行中风险的早期识别。

宏观统计虽能揭示事故总体规律, 却难以解析具体行为机理。作为飞行操作

的最终执行者，飞行员的细微操纵偏差往往是不安全事件的直接诱因。随着致命事故率下降但操作失误占比仍高，研究视角亟需从“事后归因”转向“事前行为特征挖掘”。因此，对飞行员在正常及边缘工况下的操纵轨迹、决策逻辑及动作规范性进行精细化量化分析，已成为预防风险、阻断事故链的关键。部分学者基于模拟飞行数据开展探索：Yang 等人 [27] 以 A320 机型模拟飞行数据为基础，从时效性、合规性与飞行姿态控制三个维度构建飞行员操纵性能评估体系，能够客观量化操作质量并精准识别薄弱环节；Qinbiao 等人 [28] 基于飞行仿真数据，针对着陆阶段常见的 8 类不安全事件，探究飞行员驾驶行为对运行安全的影响机制，并分析空速、风速等环境因素对着陆风险的作用路径。另外一部分研究则聚焦于真实航班的 QAR 数据。Li X. 等人 [29] 基于大规模 QAR 数据，结合专家知识提取关键特征，利用 K-means 聚类算法对拉平阶段（flare phase）中不安全的带杆操作模式进行识别，其结果可为航空公司提供操作改进建议；Li C. 等人 [30] 则综合考虑飞行员操纵行为与外部环境变量，对实际 QAR 数据进行聚类分析，揭示其在跑道超限等高风险事件中的行为特征，为相关安全问题的研究提供了新思路。

### 1.2.3 当前研究不足

现有研究在乱流的监测、识别与风险评估方面已取得显著进展，逐步形成了以雷达观测、QAR 数据分析和数值天气预报为核心的多源技术体系，为飞行安全提供了重要支撑。然而，从实际运行需求与科学研究深化的角度审视，当前方法仍面临若干关键瓶颈亟待突破。

首先，现有技术高度依赖外部气象观测设备，难以实现普适性与连续性监测。尽管多普勒天气雷达与激光测风雷达具备较强的风场探测能力，但其部署受限于地理条件与高昂的建设与维护成本，难以覆盖所有机场，尤其在复杂地形区域或中小型机场应用受限。此外，雷达系统在晴空条件下（即无降水场景）对非降水性乱流的敏感性显著下降，导致大量高风险的晴空湍流事件被遗漏，形成监测盲区。

其次，尽管 QAR 数据具有高采样频率、大样本量和真实飞行场景等优势，但多数研究将飞行参数的波动直接等同于外部风场扰动强度，未能有效解耦飞行高度变化、飞机构型调整、自动驾驶状态切换及飞行员主动操纵等非气象因素的影响。

响,易引入混杂偏差,造成乱流强度的误判。同时,现有湍流检测模型多基于黑箱机器学习或经验阈值方法,缺乏物理可解释性,难以支持安全审计、飞行员复训或运行改进建议的生成。

第三,模型不确定性量化能力不足,制约了风险分级预警的科学决策。当前研究普遍仅提供确定性的点估计结果,缺乏对预测可靠性的统计保障。在航空安全这一高可靠性要求的领域,明确预测的置信区间对于空中交通管制指令发布、机组风险规避决策及航空公司运行调度至关重要。然而,现有方法尚未建立具备有限样本覆盖率保证的区间预测框架,难以满足实际运行中对“风险边界”的量化需求。

最后,尽管人为因素被广泛认为是航空事故的主要致因,但相关研究多聚焦于事故后的归因分析,严重依赖稀疏的事故/事故征候数据,缺乏从海量正常飞行 QAR 数据中系统挖掘飞行员对外部扰动响应行为的能力。如何将飞行员操作差异(如俯仰输入、油门调节等)作为外部风场扰动的代理信号,并反向解析其人机交互机制,仍是尚未充分探索的研究方向。

综上所述,当前乱流风险评估体系在监测覆盖性、建模准确性、结果可解释性及不确定性量化等方面仍存在明显短板。因此,亟需发展一种融合 QAR 多维飞行参数、显式建模飞行员操作响应、兼具高预测性能与强可解释性、并能提供统计可靠预测区间的乱流评估新范式;进一步地,应结合机场运行视角,揭示乱流事件的时空演化规律,推动风险识别从“被动记录”向“主动预警”转型,为民航低空运行安全提供更加精准、可靠、可操作的技术支撑。

### 1.3 主要研究内容

本文聚焦于航空安全领域中的飞机进近阶段乱流研究,旨在基于航班实时的风场环境与飞行员操作 QAR 数据,构建相关评价指标,用于量化评估飞机在进近阶段风场变化对于飞行员操作的相关影响,并在机场层面进行进一步的分析。本文工作主要集中在四个方面,

首先,基于之前相关研究成果,本文采用神经网络建模风场变量与飞行高度对飞行员操作的联合影响,并引入可加性建模范式,显式分离高度效应,从而更准

确地提取气流扰动对操作响应的真实贡献，为乱流强度提供更可靠的量化基础。

其次，在所得乱流指数的基础上，构建高可解释性的回归模型：通过系统性非线性特征衍生生成候选变量集，结合神经网络训练与 SHAP (SHapley Additive exPlanations) 值进行全局特征重要性评估，筛选关键变量后与原始特征共同参与线性模型拟合，在保持预测性能的同时显著提升模型透明度与物理可解释性。

第三，引入保形预测 (Conformal Prediction, CP) 方法，为乱流指数生成具有有限样本统计保证的预测区间。该区间可在不同置信水平下提供上下界估计，支持风险分级预警，增强模型在实际运行环境中的可靠性与决策支持能力。

最后，基于多航班乱流指数结果，按日及日内时段维度进行聚合分析，绘制动态预警阈值与频率分布图，识别高风险时间窗口与典型气象场景，进而提出面向机场运行管理的安全优化建议。

本文结构如下：

第一章，引言：首先，介绍了本文的研究背景与意义。其次，对于低空风切变与乱流的监测与预测当前主要依赖于三类数据源：雷达观测、快速存取记录器 (QAR) 数据以及数值预报与其他辅助数据的相关文章进行综述，并对人为因素方面的研究进行概述，并对乱流事件相关研究现状的成果和不足进行了总结概述。接着，对本文所研究的内容与贡献进行初步简要的介绍。最后，说明本文的章节结构安排。

第二章，QAR 数据预处理与因变量生成：简单说明 QAR 数据的来源及相关基础信息。使用之前的研究结果，计算相似飞行条件下飞行员操作的 90 分位数与 10 分位数的差值，作为外部环境对飞行员操作影响的评价指标。

第三章，乱流指数的构建：首先设计双分支神经网络结构，以外部环境因素 (风变量、高度变量) 为自变量，飞行员操作变化幅度为回归目标进行模型训练，通过剥离高度等因素的影响，提取风场变量分支的输出作为初步结果。然后为提升模型透明度与物理意义，基于原始变量衍生一组新特征 (如速度梯度、加速度波动等)，结合 SHAP 值对特征重要性进行评估筛选，并进行统计学分析以确定其性质。以上一步生成的乱流指数为因变量，构建可解释性强的线性模型，揭示关键变量对乱流感知的贡献机制。

第四章，乱流强度区间估计：为有效刻画模型预测中的不确定性，在第三章研究的基础上，引入多种保形预测方法进行模型构建，估计乱流指数在不同置信水平下的上下界，形成稳健的预测区间。对整体预测覆盖率与部分航班预测情况的结果进行分析和比较，筛选出最优方法，

第五章，机场预警：在完成单架飞机飞行过程的乱流指数计算后，进一步整合特定机场在一定时间窗口内的多航班 QAR 数据，进行统计学分析，以确定航班预警方式，为机场运行管理、空管指挥优化及飞行员培训提供数据驱动的决策支持建议。

第六章，总结与展望：对论文整体完成的工作进行总结，并对本文存在的相关不足进行分析，并展望未来的可能改进。



## 第二章 QAR 数据预处理与因变量生成

### 2.1 QAR 数据介绍

自 1997 年起,中国民航全面推行飞行品质监控工程,强制要求国内运输类航空器安装快速存取记录器(Quick Access Recorder, QAR)或功能等效的设备,以实现飞行全过程数据的完整采集。2015 年,中国民用航空局飞行标准司正式发布《飞行品质监控(FOQA)实施与管理》指导性文件[31],系统规范了 FOQA 项目的运行流程与管理要求。该举措不仅显著提升了飞行安全水平,有效促进了飞行员操作行为的标准化,还为安全管理体系的持续完善提供了有力支撑,对推动我国民航业高质量、可持续发展具有深远意义。

目前, QAR 已广泛部署于国内运行的运输类航空器。借助专业 QAR 数据处理系统,可对原始记录进行高效解码,还原飞机在运行过程中三类关键的实时飞行参数:一是飞机内部性能参数,如空速、无线电高度、俯仰与滚转姿态等,用于刻画飞行状态;二是外部环境参数,包括风速、风向、气温及气压等,反映飞行所处的外部环境条件;三是飞行员操作参数,涵盖操纵杆偏移量、油门杆位置、方向舵与升降舵偏转角度等,用以量化人工操纵行为。上述参数不仅为研究人员和运行单位提供快速、便捷的原始数据访问途径,也为 QAR 海量数据的多维度挖掘与应用奠定了坚实基础。这三类参数共同构成了本研究分析风场对飞行员操作影响的基础数据基础。

本文所使用的数据集源自 2024 年某航空公司的运行记录。经过筛选,我们提取了该年度部分月份中,所有执飞至上海虹桥国际机场(SHA)并成功落地的 A320 机型航班的完整 QAR 数据。数据以 CSV 格式按航班独立存储,完整记录了从起飞至降落全过程的飞行参数。这些基于原始 QAR 解析生成的文件采用时间序列关系型结构组织:每一行代表一个秒级采样时刻,每一列对应特定飞行参数在该时刻的观测值。其具体数据结构示例如图 2.1 所示。

值得注意的是,受物理机制与采集系统的异构性影响,不同飞行参数的采样频率存在显著差异,进而影响了数据的存储结构。具体而言,高频参数(如操纵杆输

| TIME    | FLIGHT  | PHCITY | FROM | CITY | TO   | LDGL | LDGL | LDGL | LDGL | LDGNOS | LDGNOS | LDGNOS | LDGNOS | LDGR | LDGR | LDGR | LDGR | LDGR | LDGR | AILL  | AILR  | IASC   | FAILE |
|---------|---------|--------|------|------|------|------|------|------|------|--------|--------|--------|--------|------|------|------|------|------|------|-------|-------|--------|-------|
| Current | tin     | Flight | phac | City | Pair | City | Pair | City | Pair | City   | Pair   | City   | Pair   | City | Pair | City | Pair | City | Pair | City  | Pair  | City   | Pair  |
| 8:18:23 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | DEG   | DEG   | knot   | F     |
| 8:18:27 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.44 | -1.32 | 253.63 |       |
| 8:18:27 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.53 | -0.97 | 253    |       |
| 8:18:27 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 252.63 |       |
| 8:18:27 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.53 | -1.14 | 251.75 |       |
| 8:18:27 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.44 | -1.14 | 251.38 |       |
| 8:18:31 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.44 | -1.23 | 251    |       |
| 8:18:31 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.53 | -1.14 | 250.13 |       |
| 8:18:31 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.35 | -1.32 | 249.25 |       |
| 8:18:31 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.35 | -1.32 | 248.5  |       |
| 8:18:35 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.44 | -1.14 | 248.25 |       |
| 8:18:35 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 248.13 |       |
| 8:18:35 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 248.25 |       |
| 8:18:35 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 248.13 |       |
| 8:18:39 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 248.63 |       |
| 8:18:39 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.88 | -0.7  | 247.88 |       |
| 8:18:39 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.88 | -0.7  | 247.25 |       |
| 8:18:39 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.7  | -0.88 | 246.5  |       |
| 8:18:43 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.7  | -0.88 | 246.38 |       |
| 8:18:43 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.44 | -1.23 | 246.38 |       |
| 8:18:43 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.26 | -1.32 | 246.38 |       |
| 8:18:43 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.53 | -1.14 | 246    |       |
| 8:18:47 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.53 | -1.05 | 246    |       |
| 8:18:47 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.53 | -1.05 | 246.13 |       |
| 8:18:47 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.44 | -1.14 | 246.63 |       |
| 8:18:47 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.7  | -0.88 | 246.75 |       |
| 8:18:51 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.7  | -0.97 | 247.13 |       |
| 8:18:51 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 247.63 |       |
| 8:18:51 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -0.97 | 248.25 |       |
| 8:18:51 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -1.05 | 248.63 |       |
| 8:18:55 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -1.05 | 249.13 |       |
| 8:18:55 | DESCENT | ZPIH   |      |      |      | AIR  | AIR  | AIR  | AIR  | AIR    | AIR    | AIR    | AIR    | AIR  | AIR  | AIR  | AIR  | AIR  | AIR  | -0.62 | -1.05 | 249.5  |       |

图 2.1 QAR 数据格式示例

入，采样率 4Hz）每秒产生多个观测值，在数据表中以高密度形式存储；标准频率参数（如自动驾驶状态，采样率 1Hz）与时间基准严格同步，每秒对应单一记录；而低频参数（如气象风数据，采样率 < 1Hz）因更新滞后，其数值在相邻采样点间保持恒定，呈现出典型的阶梯状时序特征。这种多速率混合特性是后续数据预处理与对齐的关键挑战。

2.2 QAR 数据预处理与特征构建

2.2.1 研究样本筛选

为准确刻画进近阶段风场扰动对飞行员操纵行为的影响，本文从 QAR 参数中系统筛选出一组具有明确物理意义且与研究目标高度相关的原始变量。所选变量主要涵盖三类：一是飞行员操纵输入（如正副驾驶的俯仰操纵量），用于量化人工操纵对外部风场扰动的动态响应；二是外部环境参数（如风速、风向及无线电高度），用于直接表征进近过程中大气扰动的强度与结构特征；三是关键辅助变量（如时间戳、起落架压缩状态和自动驾驶接通情况），为精确识别进近阶段、划分飞行事件边界及对齐多源数据提供必要支持。这些变量共同构成了本研究建模与分析的基础数据集，具体选取的变量及其属性见表 2.1。

由于本研究聚焦于航班降落阶段飞行员的手动操纵行为，因此需对原始 QAR 数据进行严格筛选，以剔除非人工驾驶情境的干扰样本。首先，限定飞机处于空中

表 2.1 原始 QAR 变量说明

| 字段名称      | 含义                          | 单位         | 频率 (Hz) |
|-----------|-----------------------------|------------|---------|
| LDGL      | LH Landing Gear Com-pressed | AIR/GROUND | 4       |
| LDGR      | RH Landing Gear Com-pressed | AIR/GROUND | 4       |
| AP_EGD1   | AP1 ENGAGED                 | EGD/-      | 1       |
| AP_EGD2   | AP2 ENGAGED                 | EGD/-      | 1       |
| TIME_R    | Recorded Time               | —          | 0.25    |
| DATE_R    | Recorded Date               | —          | —       |
| GWC       | Gross Weight                | t          | —       |
| HEAD_MAG  | Magnetic heading            | deg        | 1       |
| WIN_SPD   | Wind Speed                  | KTS        | 0.25    |
| WIN_DIR   | Wind Direction              | Deg        | 0.25    |
| RALTC     | Radio Altitude (corrected)  | feet       | 4       |
| PITCH_CPT | Pitch CAPT CMD Position     | DEG        | 8       |
| PITCH_FO  | Pitch F/O CMD Position      | DEG        | 8       |

状态（即起落架未压缩或未接地信号有效），以排除地面滑跑阶段的干扰；其次，要求自动驾驶系统（Autopilot, AP）处于断开状态，确保所有操纵指令均源自飞行员的人工输入；最后，将修正无线电高度限制在 1000 英尺以下，以限定分析范围在典型的进近与着陆关键阶段，仅同时满足上述条件的数据记录被纳入最终分析集。

首先，基于起落架状态变量 LDGL 与 LDGR 判定飞机空中状态。上述变量为离散型指标，取值为 GROUND（接地）或 AIR（空中）。筛选逻辑规定，若某一秒内的任意采样点出现 GROUND 状态，即判定该时刻飞机已接地，不属于进近研究范畴，予以剔除；仅当该秒内所有采样点均保持 AIR 状态时，方确认为有效空中样本。

其次，利用自动驾驶状态变量 APEGD1 与 APEGD2 识别人工操纵时段。若任一变量的采样值包含 EGD（表示自动驾驶接通），则视为非人工直接操控，不符合研究前提而予以排除；仅当两变量在该秒内全程均为 -（表示自动驾驶关闭）时，

才认定飞机处于完全手动控制状态。

最后，依据无线电高度变量 RALTC（单位：英尺，采样率 4Hz）执行高度阈值筛选。为简化时序处理，选取每秒首个采样点作为该时刻的高度基准。考虑到后续需计算风场变化率等衍生指标，初步保留  $RALTC < 1200\text{ft}$  的数据以提供缓冲区间；待特征工程完成后，最终分析将严格限定在  $RALTC < 1000\text{ft}$  的核心范围内。为行文简洁，后文统一以 height 指代该高度变量。

经过上述多维度的筛选处理，我们获得了一组高质量、高相关性的手动操纵行为数据。这些数据真实反映了进近阶段的人工驾驶特征，为接下来建立风场扰动与操作响应的关联模型打下了坚实基础。

### 2.2.2 变量时序对齐与特征工程

在完成上述原始数据筛选后，鉴于各参数采样频率存在显著差异，需在预处理阶段通过插值、时间对齐或降采样等方法对时序数据进行统一，以支撑后续的建模与分析。针对飞行员俯仰操作（pitch）、风速（WIN\_SPD）与风向（WIN\_DIR）等关键变量，具体处理策略如下：

- **飞机俯仰角均值 (mean\_pitch)**：该变量用于表征飞行员俯仰操纵的综合强度。考虑到机长（CPT）与副驾驶（F/O）可能存在操纵权限的动态切换且主导权未知，本文采取**优先级融合策略**：优先采用机长的操作记录，仅当机长数据全为零或缺失时，才启用副驾驶数据。具体计算中，对于每一秒的观测窗口：若 PITCH\_CPT 包含非零有效值，则取其均值作为该秒代表值；否则，采用 PITCH\_FO 的均值作为替代。该策略确保了每秒均能获得合理且具有代表性的俯仰操纵强度估计。
- **风速 (WIN\_SPD)**：针对数据缺失问题，采用**线性插值法**进行填补以恢复时序连续性。例如，若第 1 秒和第 5 秒存在有效记录而中间时刻（第 2–4 秒）缺失，则基于两端点数值构建线性函数，推算出缺失时刻的风速值。
- **风向 (WIN\_DIR)**：原始数据为地理坐标系下的角度值，取值范围为  $[0^\circ, 360^\circ)$ 。由于角度具有周期性（如  $359^\circ$  与  $1^\circ$  在物理空间上相邻），直接线性插值在

跨越  $0^\circ/360^\circ$  边界时会产生严重失真。为此,本文采用**向量插值法**:首先将插值区间首尾时刻的风向  $\theta_1$  和  $\theta_2$  映射为单位向量  $\mathbf{v}_1 = (\cos\theta_1, \sin\theta_1)$  与  $\mathbf{v}_2 = (\cos\theta_2, \sin\theta_2)$ ;随后分别对向量的  $x$ 、 $y$  分量进行线性插值,得到中间时刻的合成向量  $\mathbf{v}_t$ ;最后利用四象限反正切函数将  $\mathbf{v}_t$  转换回角度制,并归一化至  $[0^\circ, 360^\circ)$  区间。该方法确保了指向性变量在几何与物理意义上的连续性与合理性。

在此基础上,为进一步挖掘风场环境中的隐含信息并增强模型对复杂扰动模式的感知能力,本文基于原始风速、风向及飞行状态变量,构造了一系列反映风场时序变化、空间离散度及向量扰动的高阶特征。这些关键变量构成了后续建模的核心输入集,具体定义与计算如下:

- **风向航向夹角 (WINHEAD)**: 定义为磁风向与飞机磁航向的夹角(单位:度),用于表征风相对于飞机纵轴的入射角度。首先计算原始角度差值  $\Delta = \text{WIN\_DIR} - \text{HEAD\_MAG}$ ,随后将其归一化至区间  $[-180^\circ, 180^\circ)$  以消除周期性不连续。具体计算规则如下:

$$\text{WINHEAD} = \begin{cases} \Delta - 360^\circ, & \text{若 } \Delta \geq 180^\circ \\ \Delta + 360^\circ, & \text{若 } \Delta < -180^\circ \\ \Delta, & \text{其他} \end{cases}$$

其中,最终结果的负值表示风来自飞机左侧,正值表示风来自右侧。

- **风速变化率 (WINSPD\_DIFF)**: 表征风速的瞬时变化趋势,定义为当前时刻与前一时刻的风速差值:

$$\text{WINSPD\_DIFF}_t = \text{WIN\_SPD}_t - \text{WIN\_SPD}_{t-1}$$

- **风向变化率 (WINDIR\_DIFF)**: 表征风向的瞬时偏转幅度。首先计算原始角度差值  $\Delta = \text{WIN\_DIR}_t - \text{WIN\_DIR}_{t-1}$ ,随后采用与 WINHEAD 相同的周期性映射规则,将结果归一化至  $[-180^\circ, 180^\circ)$  区间,以准确反映风向变化的最小旋转

路径及方向性：

$$\text{WINDIR\_DIFF}_t = \begin{cases} \Delta - 360^\circ, & \text{若 } \Delta \geq 180^\circ \\ \Delta + 360^\circ, & \text{若 } \Delta < -180^\circ \\ \Delta, & \text{其他} \end{cases}$$

- **短时风速均值 (WINSPD\_mean)**: 反映过去 4 秒（含当前时刻  $t$ ）的风速平均水平，用于平滑高频噪声并捕捉短期风场趋势：

$$\text{WINSPD\_mean}_t = \frac{1}{4} \sum_{i=t-3}^t \text{WIN\_SPD}_i$$

- **短时风速标准差 (WINSPD\_std)**: 衡量过去 4 秒内风速的波动强度（乱流强度指标之一）：

$$\text{WINSPD\_std}_t = \sqrt{\frac{1}{4} \sum_{i=t-3}^t (\text{WIN\_SPD}_i - \text{WINSPD\_mean}_t)^2}$$

- **短时风向波动程度 (WINHEAD\_DISCENT)**: 基于圆形统计学 (Circular Statistics) 构造的指标，用于量化过去 4 秒内相对风角的集中程度。令平均余弦分量  $\bar{C}_t$  与平均正弦分量  $\bar{S}_t$  分别为：

$$\bar{C}_t = \frac{1}{4} \sum_{i=t-3}^t \cos(\text{WINHEAD}_i), \quad \bar{S}_t = \frac{1}{4} \sum_{i=t-3}^t \sin(\text{WINHEAD}_i)$$

则离散度指标定义为：

$$\text{WINHEAD\_DISCENT}_t = 1 - \sqrt{\bar{C}_t^2 + \bar{S}_t^2}$$

该指标取值范围为  $[0, 1]$ ：值越接近 0，表示风向越集中（稳定）；值越接近 1，表示风向越分散（剧烈波动）。

- **风向量综合变化率 (WIN\_VEC\_VARIATION)**: 综合反映风速大小与风向角度的联合变化强度，是衡量风场矢量扰动的核心特征。记  $s_i = \text{WIN\_SPD}_i$  为风速， $\phi_i = \text{WIN\_DIR}_i$  为风向（弧度制），则相邻时刻风向量在极坐标下的欧氏距离  $d_i$  为：

$$d_i = \sqrt{s_i^2 + s_{i-1}^2 - 2s_i s_{i-1} \cos(\phi_i - \phi_{i-1})}$$

该指标定义为过去 4 秒内  $d_i$  的均值：

$$\text{WIN\_VEC\_VARIATION}_t = \frac{1}{4} \sum_{i=t-3}^t d_i$$

数值越大，表明风场的矢量特性变动越剧烈，是后续分析中衡量风场扰动强度的关键依据。

- **飞机总重 (Weight):** 直接采用原始数据中的 GWC 变量，单位为吨 (t)，作为反映飞机惯性特性的关键状态变量参与建模。

最后，为支持基于时间维度的机场运行特性分析，本文对原始时间戳字段 TIME\_R 和 DATE\_R 进行了精细化解析，提取并重构了飞行事件发生的具体日期与时间信息（精度精确至分钟），以构建完整的时间索引特征。

在完成上述特征工程后，我们将每条秒级飞行轨迹数据实例化为一条独立记录，并关联对应的航班标识符，最终汇编成统一的时序数据集。本研究聚焦于 3 月份的气象与飞行数据，该月的原始数据覆盖范围为 2,604 架次航班。经过严格的数据质量筛查与异常值剔除，共有 2,570 架次航班保留了有效数据，数据可用率为 98.7%。最终，构建得到的 3 月有效数据集共包含 182,652 条秒级记录，将作为后续模型训练与分析的核心基础。

### 2.3 响应变量构建

在既有研究中，徐沐彦 [32] 创新性地提出了一种基于飞行员操作行为的风场乱流强度表征方法。该方法利用相同风场环境下飞行员操作数据的四分位距 (IQR, 即第 90 百分位数与第 10 百分位数之差,  $P_{90} - P_{10}$ ) 来量化风场对航班运行的影响。其核心机理在于：当气流特征剧烈变化时，飞行员需采取更多样化或大幅度的操纵策略以应对复杂情况，导致操作数据的离散度 (IQR) 显著增大；反之，在平稳气流中，飞行员的操作趋于单一且幅度微小，IQR 值随之降低。该方法的创新性主要体现在两方面：首先，建立了风场物理特性与飞行员行为响应之间的直接映射关系，将主观的操纵行为转化为客观、可量化的风场影响代理指标；二是引入分位数区间 ( $P_{10} - P_{90}$ ) 替代全样本统计量，有效剔除了复飞、紧急修正等异常操纵带

来的异常值干扰，通过聚焦中间 80% 的典型操作分布，更稳健、精准地刻画了常规扰动下的飞行员主要操纵模式。

然而，原方法在界定“相似环境”时仅局限于风场变量，后续研究揭示了这一假设的局限性：响应变量（即表征操作幅度的 IQR）与飞行高度存在显著的相关性。图2.2展示了不同无线电高度区间下响应变量的分布特征。数据显示，随着飞行高度的降低（从 500–1000 ft 降至 0–50 ft），飞行员操作幅度的中位数及离散程度均呈现明显的上升趋势。




图 2.2 响应变量与高度的相关性




图 2.3 风场复杂度与高度的相关性

这一相关性源于物理环境与操作策略的共同作用。一方面，风场本身的复杂性随高度变化显著，尤其在着陆阶段（低高度区），风场变化的激烈程度将显著升高（如图2.3所示）；另一方面，飞行员在低高度进近阶段需执行更精细、频繁的轨迹修正操作。因此，若忽略高度这一关键协变量，直接利用原响应变量描述风场影响将引入系统性偏差。

为更全面地刻画风场对飞行员操作的影响，本文对原有方法进行了改进：将“相似环境”的定义从单一的风场相似性，拓展至包含飞行高度、飞机重量等多维特征的综合相似性。

具体而言,选取风速、风向变化率、风速标准差、无线电高度 (height) 及飞机重量 (weight) 构建多维特征向量。针对处于自动驾驶停用状态的 182,652 个有效样本点,本研究基于欧氏距离度量,在全样本空间中执行  $K$  近邻 ( $K$ -NN) 搜索。针对每一个目标样本,检索与其特征向量最相似的 499 个邻近样本 (含自身共 500 个数据点),从而构建反映局部风场特性的邻域集合。随后,计算每个邻域内俯仰角均值 (mean\_pitch) 的 10% 分位数 ( $P_{10}$ ) 与 90% 分位数 ( $P_{90}$ ),并将二者之差定义为新的局部乱流响应指标 iqr\_pitch,用于量化该局部环境下的飞机姿态波动范围。

需要注意的是,尽管通过多维聚类构建了局部邻域,但得到的 iqr\_pitch 仍隐含了高度效应的残余影响——即不同高度层的基准操作离散度存在系统性差异。因此,该指标尚不能直接作为纯风场影响的估计。后续章节将探讨如何有效地剥离高度效应,构建一个解耦高度影响的风场扰动评估模型。



## 第三章 乱流指数构建

### 3.1 基于神经网络的乱流指数构建

#### 3.1.1 相关研究

在既有研究中, 徐沐彦 [32] 将前文构建的局部俯仰操作离散度指标  $iqr\_pitch$  视为一个加性模型。该研究假设  $iqr\_pitch$  主要由三部分构成: 高度导致的操作波动、风场环境引起的操作波动以及随机误差项。用  $f(height)$  表示高度效应,  $g(winds)$  表示风场效应 (其中  $winds$  代表风场特征变量集合),  $\varepsilon$  表示随机误差, 则该模型可形式化表示为:

$$iqr\_pitch = f(height) + g(winds) + \varepsilon \quad (3.1)$$

基于上述假设, 研究人员采用半参数回归模型 (Semiparametric Regression Model) 进行拟合。其中, 高度效应  $f(\cdot)$  被设定为关于无线电高度的非线性光滑函数 (如平滑样条), 以捕捉其复杂的趋势变化; 而风场效应  $g(\cdot)$  则被约束为风场变量的线性组合, 以保持模型的可解释性。模型训练完成后, 其拟合值可表示为:

$$\widehat{iqr\_pitch} = \hat{f}(height) + \hat{g}(winds) \quad (3.2)$$

在该框架下, 最终的乱流指数被定义为风场效应分量  $\hat{g}(winds)$ , 即剔除高度影响后的风场变量线性预测值。

尽管该方法在初步分离高度效应方面取得了进展, 但仍存在以下局限性:

- **模型结构过于简化:** 将风场效应强制约束为线性组合, 虽然保证了系数的可解释性, 但忽略了气象变量之间普遍存在的非线性交互作用 (例如风速突变与风向剪切率的耦合效应)。这种线性假设可能导致在极端复杂风场下的评估失真。
- **拟合精度与分离效果受限:** 受限于模型形式的限制, 该半参数模型对原始响应变量  $iqr\_pitch$  的整体拟合优度往往低于随机森林、梯度提升树等现代机器学习算法。较低的拟合精度意味着残差  $\varepsilon$  中可能包含未被解释的系统性变异,

进而导致高度效应  $f(\cdot)$  与风场效应  $g(\cdot)$  的分离不够彻底，使得最终指数仍残留部分高度依赖性。

上述不足表明，为了更准确地量化纯风场影响，有必要引入更具表达能力的非线性建模策略，在提升拟合精度的同时，更彻底地剥离高度效应，从而构建高可靠性的乱流指数。

### 3.1.2 神经网络分离高度影响策略

鉴于前述方法的不足，本节在保持原始加性模型宏观架构不变的基础上，对分解模型：

$$\text{iqr\_pitch} = f(\text{height}) + g(\text{winds}) + \varepsilon \quad (3.3)$$

中的函数  $f(\cdot)$  与  $g(\cdot)$  进行重构。我们尝试采用具有更强非线性表达能力的神经网络结构，以更精确地拟合风场变量及飞行员操作之间复杂的非线性映射关系。

综合考量模型预测精度与高度效应解耦的需求，本文提出一种双支路可加神经网络架构（Dual-Branch Additive Neural Network）。该架构的核心约束在于两个支路在网络结构上完全独立，仅在输出端进行线性叠加：

- **高度支路：**仅以飞行高度（height）及其衍生特征作为输入，专门捕捉高度引致的系统性变异；
- **风场支路：**以风场及相关环境变量集（记为 winds）作为输入，专门学习环境扰动引致的操作波动。

两支路的输出直接相加构成最终预测值：

$$\widehat{\text{iqr\_pitch}} = \hat{f}(\text{height}) + \hat{g}(\text{winds})$$

模型通过最小化预测值与真实响应变量之间的残差平方和进行端到端训练。本研究采用的风场相关输入变量详见表 3.1。值得注意的是，相较于原研究，本模型新增了 Weight（飞机重量）与 WIN\_VEC\_VARIATION（风速风向综合变化值）两个关键物理特征，以增强对环境状态的表征能力。

表 3.1 风场相关输入变量说明

| 变量名               | 物理含义        |
|-------------------|-------------|
| WIN_SPD           | 风速          |
| WINSPD_std        | 风速标准差       |
| WINHEAD_abs       | 风向与航向夹角的绝对值 |
| WINDIR_DIFF_abs   | 瞬时风向变化量的绝对值 |
| WIN_VEC_VARIATION | 风速与风向的综合变化值 |
| WINHEAD_DISCENT   | 风向波动程度      |
| Weight            | 飞机重量        |

于神经网络原理，若仅将 **height** 作为单一线性标量输入，浅层网络对其非线性趋势的拟合能力将受到显著限制。为此，我们在高度支路的输入层引入了先验非线性变换特征  $h(\text{height})$ 。经多种基函数形式的对比实验（包括对数、多项式及幂函数），最终选定  $\sqrt{\text{height}}$  作为辅助特征参与训练。

为验证该策略的有效性，本研究将重点考察以下三个维度：

- **模型精度提升**：新架构是否显著降低了整体预测误差（MSE/RMSE）；
- **高度效应剥离的合理性**： $\hat{f}(\text{height})$  的曲线形态是否符合物理直觉，能否准确表征由高度降低导致的操作波动系统性增长；
- **指标敏感性与解耦有效性**：首先考察  $R = \text{iqr\_pitch} - \hat{f}(\text{height})$  的物理属性，验证其是否显著反映了风场变量和飞行员操作的变化；在此基础上，评估模型学习到的  $\hat{g}(\text{winds})$  是否能够充分逼近该残差项。只有当残差项本身被证实为“纯净”的风场响应时， $\hat{g}(\text{winds})$  作为乱流强度指标的合理性才成立。

在训练过程中，网络通过最小化均方误差（MSE）进行优化，其目标函数定义为：

$$\mathcal{L} = \mathbb{E} \left[ \left( \text{iqr\_pitch} - \hat{f}(\text{height}) - \hat{g}(\text{winds}) \right)^2 \right] \quad (3.4)$$

在此优化目标下，由于两支路输入互斥，若  $\hat{f}(\text{height})$  能够充分拟合高度引致的系统性变异，则剩余变异将主要由风场及环境因素驱动。这将迫使环境支路  $\hat{g}(\text{winds})$

自动学习并逼近这部分变异的最佳估计，从而实现盲源分离的效果。

因此，在模型容量充足且训练收敛的理想情况下，满足：

$$\hat{g}(\text{winds}) \approx \text{iqr\_pitch} - \hat{f}(\text{height}) \tag{3.5}$$

这意味着  $\hat{g}(\text{winds})$  可被视为剔除了高度混淆因子后的“纯净”风场响应，适宜作为测试集上评估风场扰动强度的核心指标。

3.1.3 模型结果评价

在测试集与训练集的划分上，本文采用基于航班的分割策略，以避免因同一航班内时序观测高度自相关而导致的评估偏差。原始数据集共包含 2024 年 3 月份 2,570 架次在上海虹桥国际机场降落的 A320 航班，总计 182,652 条秒级观测记录，平均每架航班在 1000 英尺以下进近阶段贡献约 70 条有效数据（标准差为 18.4）。划分时，按航班 ID 随机抽取 70% 的航班（1,799 架次，对应 128,294 条记录）作为训练集，剩余 30% 的航班（771 架次，对应 54,358 条记录）作为测试集。该策略确保同一航班的所有观测记录完整归属于训练集或测试集之一，有效防止了数据穿越，并更真实地模拟模型在面对全新航班时的泛化性能。

在完成神经网络和半参数模型的相关训练后，进行模型效果的检验。首先从初始的模型拟合度角度对结果进行比较，考察神经网络方法与半参数模型方法对响应变量的拟合效果，即  $\widehat{\text{iqr\_pitch}}$  对  $\text{iqr\_pitch}$  的拟合效果。在测试集上的评估结果如表 3.2 所示。

表 3.2 不同模型对  $\text{iqr\_pitch}$  在测试集上的拟合性能对比

| 方法      | 均方误差 ( $MSE$ ) | 平均绝对误差 ( $MAE$ ) | 决定系数 ( $R^2$ ) |
|---------|----------------|------------------|----------------|
| 双分支神经网络 | 0.1037         | 0.2493           | 0.8899         |
| 半参数回归模型 | 0.1288         | 0.2924           | 0.8633         |

从表中可见，双分支神经网络在三项评价指标上均显著优于半参数回归模型：其均方误差（MSE）由 0.1288 降至 0.1037，平均绝对误差（MAE）从 0.2924 降低至 0.2493，同时决定系数（ $R^2$ ）由 0.8633 提升至 0.8899。这一改进表明，神经网络

络不仅在整体预测精度上更具优势，而且在捕捉复杂响应模式方面表现更为稳健。其性能提升主要源于模型结构对风场相关变量（如风速、风向、重量及其衍生特征）之间非线性关系与高阶交互效应的更强表达能力；相比之下，半参数模型对风场部分采用线性假设，难以充分刻画飞行员在多维扰动环境下的非线性操纵响应。因此，神经网络所获得的更优拟合效果，为后续高度效应的准确剥离以及乱流指数的可靠构建奠定了坚实基础。

为验证所提出模型中高度效应分离的合理性，本文考察了神经网络输出的  $\hat{f}(\text{height})$  随无线电高度的变化趋势。如图 3.1 所示，




图 3.1 高度对飞行员操作波动的影响趋势

其中，红色散点表示各观测时刻  $\hat{f}(\text{height})$  的取值，蓝色曲线为基于局部加权回归（LOWESS）得到的平滑趋势线。可见，随着高度从 1000 英尺逐渐降低至着陆阶段， $\hat{f}(\text{height})$  呈现显著上升趋势，表明飞行员在低空阶段的操作波动性系统性增强。

这一现象与飞行实践高度一致：在进近末段，飞行员需应对更高的精度要求与更频繁的微调操作，导致操纵输入趋于活跃。因此， $\hat{f}(\text{height})$  成功捕捉了由飞行阶段本身驱动的系统性操作变化，验证了其作为高度主效应代理变量的合理性，也进一步支持了后续  $\text{iqr\_pitch} - \hat{f}(\text{height})$  用于表征风场扰动的有效性。

下面考察  $\text{iqr\_pitch} - \hat{f}(\text{height})$  对于风场的反应能力。为直观揭示乱流指数与风场变化特征之间的关系，本文采用小提琴图结合均值折线图的复合可视化方法。

具体构建方式如下：将样本中的乱流指数按其取值范围进行等频十等分（即划




图 3.2 神经网络乱流指数与风场的相关性

分为 10 个分箱)，每个分箱代表一个乱流强度区间，作为横轴的分类单元；在每个分箱内，于主坐标轴（左侧 Y 轴）绘制变量 WIN\_VEC\_VARIATION 的小提琴图，该变量综合反映风速与风向在 4 秒内的联合变化强度，其分布通过核密度估计呈现，可清晰展示数据的集中趋势、离散程度及潜在的多峰结构；同时，在副坐标轴（右侧 Y 轴）的对应横坐标位置上，叠加绘制各分箱内 WIN\_VEC\_VARIATION 的均值，并以红色折线连接，用以刻画风场变化强度随乱流指数增强而演变的平均响应趋势。

绘制后得到图 3.2。图像显示，所构建的乱流指数可以有效反映风场整体的强度，具体表现为指数的数值越大，整体的风场强度就越大。并且乱流指数与风场均值的关系呈严格单调递增，说明不同强度区间之间具有良好的区分度，对风场变化的评估具有一定指导作用。

此外，为了评估乱流对航班过程中飞行员操作幅度的影响，尤其是俯仰角操作的变化，我们绘制了以下复合图：将样本中的乱流指数按其取值范围进行等频十等分（即划分为 10 个分箱），每个分箱代表一个乱流强度区间，作为横轴的分类单元；在每个分箱内，于主坐标轴（左侧 Y 轴）绘制变量 mean\_pitch 的小提琴图，该变量表示飞行员在对应乱流条件下的平均俯仰角调整幅度，其分布通过核密度估计呈现，能够清晰反映操作幅度的集中趋势、离散程度及潜在的多峰结构；同时，

在副坐标轴（右侧 Y 轴）的对应横坐标位置上，叠加绘制各分箱内  $\text{mean\_pitch}$  的 90 分位数与 10 分位数之差，并以折线形式连接，用以刻画不同乱流强度下飞行员操作幅度分布宽度的变化趋势，从而间接揭示操作难度或不稳定性随乱流增强而上升的特征。




图 3.3 神经网络乱流指数与飞行员操作的相关性

由图 3.3 可以发现，利用神经网络所构建的乱流指数在指标较低时，飞行员总体操作变化幅度存在非单调部分，可能导致低风险区间的误判；但在高风险阶段表现良好。总体而言，该指数能有效反映飞行员操作的变化幅度，具体表现为指数数值越大，飞行员操作的 IQR 值也越大。值得注意的是，半参数线性回归模型的结果在最小分箱处的 90 分位数与 10 分位数之差仅略小于最大分箱（分别为 4.82 与 5.00）。

在前述分析的基础上，神经网络输出的风场效应分量  $\hat{g}(\text{winds})$  若能准确逼近残差  $\text{iqr\_pitch} - \hat{f}(\text{height})$ ，则其可作为无需依赖原始响应变量的、可泛化的乱流指数，适用于新航班的风险评估。因此，有必要检验  $\hat{g}(\text{winds})$  与  $\text{iqr\_pitch} - \hat{f}(\text{height})$  之间的一致性。为评估这一性质，我们计算了两种方法下上述两组序列的 Pearson 相关系数与 Spearman 秩相关系数，结果如表 3.3 所示。

在此，我们并不要求两者在数值上完全吻合，而更关注其排序一致性：即原始数据中风场影响较大的样本（表现为较高的  $\text{iqr\_pitch} - \hat{f}(\text{height})$ ）在模型输出中也

表 3.3 不同方法对风场影响拟合的相关性对比

| 方法    | Pearson 相关系数 | Spearman 秩相关系数 |
|-------|--------------|----------------|
| 神经网络  | 0.6418       | 0.5993         |
| 半参数模型 | 0.4998       | 0.4837         |

应保持相对较高的排序。结果显示，神经网络方法在 Spearman 秩相关系数上显著优于半参数模型 (0.5993 vs. 0.4837)，表明其预测的  $\hat{g}(\text{others})$  能更好地保持原始风场影响强度的相对排序。

综合考虑上述指标的结论，并鉴于排序一致性是衡量“风场影响能否被真实反映”的关键标准，本文最终采用神经网络方法作为分离高度效应、提取风场影响的核心建模策略。

## 3.2 可解释模型的构建

### 3.2.1 新响应变量与线性模型

在前文分析中，我们提出了一种更为合理的高度变量分离方法，并构建了一个可用于量化乱流影响强度的新变量，即前文的  $\hat{g}(\text{winds})$ 。

然而，神经网络在拟合复杂非线性关系方面表现优异，但是“黑箱”特性缺乏可解释性，难以满足实际航空应用场景对模型透明度和可信度的要求，因此我们不使用得到的  $\hat{g}(\text{winds})$  作为最终的结果模型，只是保留双支神经网络中对于高度影响的拟合部分，将  $\text{iqr\_pitch} - \hat{f}(\text{height})$  视作新的因变量，定义为  $\text{iqr\_pitch\_wind}$ ，并希望仅仅以风场变量作为自变量，构建可解释性强的模型进行相关拟合。原问题变为如下回归形式：

$$\text{iqr\_pitch\_wind} = g(\text{winds}) + \varepsilon$$

其中  $\text{winds}$  为风场相关的变量。最简化的策略是假设  $g(\cdot)$  为  $\text{winds}$  的线性组合。这里  $\text{winds}$  仍然选择表3.1中的相关变量，基于此设定进行训练后，得到如下结果：

尽管该线性模型具有良好的可解释性，但其预测精度显然有限，难以充分捕捉风场变量与飞行员操作响应之间的复杂非线性关系。为在保留模型透明度的前

表 3.4 线性模型在测试集上的性能评价指标

| 评价指标 | 均方误差 (MSE) | 平均绝对误差 (MAE) | 决定系数 ( $R^2$ ) |
|------|------------|--------------|----------------|
| 线性模型 | 0.1303     | 0.2941       | 0.2409         |

提下提升拟合性能，我们对原始风场相关变量进行了系统的特征衍生。

3.2.2 新变量生成与筛选

在进行风向数据建模时，需特别注意原始变量 WINHEAD 的周期性特性。在前期探索中，曾尝试将风向角度统一映射至  $(-180^{\circ}, 180^{\circ}]$  区间后取绝对值，以简化其与飞行操作的关系建模。然而，该方法虽能部分捕捉风向强度的影响，却不可逆地丢失了方向信息——无法区分左侧风与右侧风等关键飞行情境，从而削弱了模型对飞行员操纵行为的解释能力。

为克服这一局限，本文采用更为合理的编码策略：将 WINHEAD（以弧度为单位）通过三角函数映射为两个正交分量：

$$x_{\sin} = \sin(\text{WINHEAD}), \quad x_{\cos} = \cos(\text{WINHEAD}),$$

分别记为 WINHEAD\_SIN 与 WINHEAD\_COS。该变换不仅严格保留了角度的周期性与连续性（例如  $0^{\circ}$  与  $360^{\circ}$  映射至相同坐标点），还能自然用正负表现风向对飞行操作的两个物理维度，表 3.5 进一步总结了这两个分量符号组合所对应的飞行场景语义。

表 3.5 风向航向夹角三角函数值物理意义

| WINHEAD_COS 正负值 | WINHEAD_SIN 正负值 | 飞机左右侧 | 航行顺逆风 |
|-----------------|-----------------|-------|-------|
| +               | +               | 右侧    | 逆风    |
| +               | -               | 左侧    | 逆风    |
| -               | +               | 右侧    | 顺风    |
| -               | -               | 左侧    | 顺风    |

即余弦值的正负决定航班当前状态为顺风或逆风，正弦值的正负决定风吹响机体的来向为左侧或右侧。为进一步探究这些方向分量对飞行员操纵行为的作用

机制策略, 将 WINHEAD\_COS 与 WINHEAD\_SIN 分别划分为若干区间, 确保每个区间包含大致相等的样本数量, 从而避免因样本稀疏导致的偏差。在此基础上, 琴形图以展示各区间内 mean\_pitch 的完整分布形态, 并叠加 90% 分位数与 10% 分位数差值的折线图, 用于刻画不同风况下飞行员操作的离散程度与趋势变化。具体结果如图 3.4 与图 3.5 所示。




图 3.4 WINHEAD\_COS 与飞行员俯仰操作 (mean\_pitch) 的相关性

图 3.4 显示, 随着 WINHEAD\_COS 从负值 (顺风) 向正值 (逆风) 过渡, mean\_pitch 的分布中心逐渐上移, 且整体波动性显著降低。特别地, 在 WINHEAD\_COS > 0 的区间内 (即逆风条件), 绝大多数航班选择在此条件下完成降落, 这与航空运行规范一致——逆风可增加升力、缩短滑跑距离并提升飞行稳定性。此外, 90 分位数减去 10 分位数范围在逆风区域趋于收敛, 表明飞行员操作更趋稳定; 而在顺风区域 (WINHEAD\_COS < 0), 尽管样本较少, 但 mean\_pitch 的分布明显更宽, 反映出飞行员需施加更大控制输入以补偿气流扰动, 操作难度与安全风险显著上升。

图 3.5 表明, 左侧风 (WINHEAD\_SIN < 0) 与右侧风 (WINHEAD\_SIN > 0) 的样本分布基本均衡。然而, 当风从左侧接近垂直方向吹来时 (WINHEAD\_SIN  $\approx -1$ ), mean\_pitch 的变异系数最大, 琴形图呈现明显的双峰结构, 说明此类风况对飞行员操控具有更强的挑战性。理论上, 左右侧风应对策略应具对称性, 但本文




图 3.5 WINHEAD\_SIN 与飞行员俯仰操作 (mean\_pitch) 的相关性

所用单月全量数据可能受限于特定机场的跑道布局、主导风向或季节性气象特征，导致实际运行中左右侧风暴露存在系统性偏差，进而表现为操作响应的非对称性。

综上, WINHEAD\_COS 与 WINHEAD\_SIN 不仅有效编码了风向的循环结构, 还揭示了其对飞行员操作的差异化影响机制。因此, 在后续建模中, 本文将这两个变量作为核心输入特征纳入不确定性量化框架, 以提升预测区间对风场动态的适应能力。除此之外, 尝试引入一些非线性因素, 我们考虑引入 SHAP 值对神经网络中变量的重要性进行相应分析。

在复杂机器学习模型（如深度神经网络、梯度提升树）日益普及的背景下，模型的“黑箱”特性严重制约了其在医疗、金融、司法等高风险决策领域的可信应用。因此，可解释人工智能 (Explainable AI, XAI) 成为研究热点。其中，SHAP (SHapley Additive exPlanations) 作为一种基于博弈论的特征归因方法，因其坚实的理论基础和直观的解释能力，迅速成为最广泛使用的模型解释工具之一。SHAP 的核心思想源于合作博弈论中的 Shapley 值。Lundberg 和 Lee[33] 系统地将 Shapley 值引入机器学习解释领域，提出了 SHAP 框架，并证明 SHAP 值是唯一能够同时满足局部准确性 (local accuracy)、缺失性 (missingness) 和一致性 (consistency) 的特征归因方法，从而为模型解释提供了统一且理论最优的解决方案。为了应对不同模型类型的计算挑战，SHAP 框架发展出了一系列高效算法：TreeSHAP[34] 专为树集

成模型（如随机森林、XGBoost）设计；DeepSHAP 通过反向传播机制近似 Shapley 值；KernelSHAP 则通过加权线性回归在扰动样本上近似 Shapley 值。同时，SHAP 值还可聚合用于全局模型理解，揭示模型的整体行为模式。

表 3.6 参与衍生风场相关特征变量说明

| 变量名               | 物理含义或计算方式      |
|-------------------|----------------|
| WIN_SPD           | 原始风速           |
| WINHEAD_DISCENT   | 风向变化率          |
| WINSPD_mean       | 滑动窗口内风速的均值     |
| GW_LD             | 接地载荷           |
| WIN_VEC_VARIATION | 风矢量变化强度        |
| WINSPD_std        | 滑动窗口内风速的标准差    |
| WINHEAD_COS       | 原始风向和航向的夹角的余弦值 |
| WINHEAD_SIN       | 原始风向和航向的夹角的正弦值 |
| WINSPD_DIFF       | 相邻时刻风速的差分      |

为更充分地挖掘风场变量中蕴含的信息，在表 3.1 所列变量的基础上，我们对输入特征集进行了优化与调整，剔除了冗余或贡献度较低的原始变量，修正后的变量清单详见表 3.6。

在初步确定用于衍生的风场相关变量后，本文进入系统的特征生成与筛选阶段。为兼顾模型性能与可解释性，采用基于 SHAP 值的特征重要性评估方法，结合多层感知机（MLP）神经网络作为基础预测模型，对候选特征进行量化分析与优选。整个流程分为以下四个步骤：

**Step 1: 非线性特征构造** 以原始风场及相关变量为基础，系统构建高阶非线性衍生特征。设原始连续变量集合为  $\mathcal{X} = \{x_1, x_2, \dots, x_p\}$ ，本文对其中所有变量生成平方项  $x_i^2$ ，所有两两不同变量的乘积项  $x_i \cdot x_j$  ( $i < j$ )，以及所有满足分母非零条件的比值项  $x_i/x_j$  ( $i \neq j$  且  $x_j \neq 0$ )。为避免比值运算中出现除零或负值导致的数值不稳定问题，特别对风速差分变量 WINSPD\_DIFF 进行预处理：将其替换为  $|\text{WINSPD\_DIFF}| + 1$ 。在此基础上，对全部候选特征进行初步清洗，剔除方差为零的恒定特征，以及缺失率或异常值比例超过阈值  $\tau = 0.1$  的变量，最终保留有效特

征用于后续建模。

**Step 2: 神经网络训练** 将 Step 1 生成的新特征与原始变量以及作为协变量的飞行高度 height) 合并, 构成完整输入特征向量  $\mathbf{z} \in \mathbb{R}^d$ , 并以 iqr\_pitch 作为目标变量  $y$ , 训练一个多层感知机 (MLP) 模型:

$$y = f_{\text{MLP}}(\mathbf{z}; \boldsymbol{\theta}) + \varepsilon,$$

其中  $\boldsymbol{\theta}$  为网络参数,  $\varepsilon$  为残差项。该模型用于捕捉风场变量与飞行员操作响应之间的复杂非线性关系。

**Step 3: 基于 SHAP 的变量重要性评估与初筛** 利用 SHAP (SHapley Additive exPlanations) 方法对训练完成的 MLP 模型进行全局解释, 计算每个输入特征  $z_k$  的平均绝对 SHAP 值:

$$\phi_k = \frac{1}{N} \sum_{i=1}^N |\phi_k^{(i)}|,$$

其中  $\phi_k^{(i)}$  为第  $i$  个样本中特征  $z_k$  的 SHAP 贡献值,  $N$  为样本总数。按  $\phi_k$  降序排序, 选取前 20 个对模型输出贡献最大的特征作为候选集。

**Step 4: 迭代优化与最终变量确定** 考虑到高度 height 对飞行员操作的影响已在前期通过函数  $f(\text{height})$  建模并从响应变量中剥离, 若 Step 3 筛选出的特征中仍包含与 height 高度相关的变量 (如相关系数  $|\rho| > 0.7$ ), 则予以剔除, 以避免重复建模。随后, 对剩余变量重新执行 Step 1 至 Step 3 的流程, 进行第二轮特征衍生与 SHAP 筛选, 最终确定一组既具预测能力又具备物理可解释性的核心风场特征, 用于构建后续的线性回归模型。

在完成初步的特征衍生与计算后, 我们获得了一批新的候选变量。为确保模型的稳定性与可解释性, 对这些变量依次进行了**方差筛选** (剔除近似常量)、**相关性分析** (避免信息冗余) 以及**多重共线性检验** (如 VIF 指标), 最终保留了一组具有非线性表达能力且统计性质良好的核心特征。相关信息如表3.7

### 3.2.3 可解释线性模型的构建与模型结果

在完成上述高阶非线性特征构造后, 候选变量集显著扩充, 其中大量通过乘积与比值生成的组合特征虽数学上有效, 但其物理含义往往难以直观解释。为在

表 3.7 各特征变量的均值与标准差

| 变量名称                                                                                                  | 均值        | 标准差       |
|-------------------------------------------------------------------------------------------------------|-----------|-----------|
| WINHEAD_COS                                                                                           | 0.5463    | 0.4888    |
| WINHEAD_SIN                                                                                           | -0.2270   | 0.6411    |
| $\text{Weight}^2 \cdot \text{WINHEAD\_COS} \cdot \text{WINHEAD\_SIN}$                                 | -562.8283 | 1423.2201 |
| $\text{Weight} \cdot ( \text{WINSPD\_DIFF}  + 1) \cdot \text{WINSPD\_mean} \cdot \text{WINHEAD\_SIN}$ | -266.0220 | 567.8128  |
| $\text{Weight}^2 / ( \text{WINSPD\_DIFF}  + 1)^2$                                                     | 2640.9127 | 1145.0143 |
| $\text{Weight} \cdot \text{WIN\_SPD} \cdot \text{WINHEAD\_COS} / ( \text{WINSPD\_DIFF}  + 1)$         | 258.8957  | 269.4848  |
| $\text{Weight} \cdot \text{WINHEAD\_COS}^2$                                                           | 34.6237   | 22.1941   |
| $\text{Weight} \cdot \text{WINHEAD\_SIN}^2 \cdot \text{WINSPD\_mean}$                                 | 234.2602  | 224.8608  |

模型性能与可解释性之间取得平衡，本文采用 Lasso（Least Absolute Shrinkage and Selection Operator）正则化方法对全部候选特征进行稀疏筛选。Lasso 通过引入  $L_1$  范数惩罚项，在最小化预测误差的同时自动将不重要变量的系数压缩至零，从而实现特征选择。该方法不仅有效控制模型复杂度、缓解过拟合风险，还能保留对目标变量具有显著解释力的特征子集。

基于 Lasso 筛选结果，本文最终选取以下 13 个变量构建线性回归模型：

表 3.8 Lasso 筛选后入模变量分类

| 类别       | 变量名称（数学表达式形式）                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|----------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 基础风场变量   | WINSPD_std, WINHEAD_DISCENT, WIN_SPD,<br>GW_LD, WIN_VEC_variation,<br>WINHEAD_cos, WINHEAD_sin                                                                                                                                                                                                                                                                                                                                                                         |
| 高阶交互与比值项 | $\text{Weight}^2 \cdot \text{WINHEAD\_COS} \cdot \text{WINHEAD\_SIN}$ ,<br>$\text{Weight} \cdot ( \text{WINSPD\_DIFF}  + 1) \cdot \text{WINSPD\_mean} \cdot \text{WINHEAD\_SIN}$ ,<br>$\text{Weight}^2 / ( \text{WINSPD\_DIFF}  + 1)^2$ ,<br>$\text{Weight} \cdot \text{WIN\_SPD} \cdot \text{WINHEAD\_COS} / ( \text{WINSPD\_DIFF}  + 1)$ ,<br>$\text{Weight} \cdot \text{WINHEAD\_COS}^2$ ,<br>$\text{Weight} \cdot \text{WINHEAD\_SIN}^2 \cdot \text{WINSPD\_mean}$ |

最终模型以这些筛选后的变量作为输入，采用普通最小二乘法（OLS）进行拟

合。尽管模型结构保持线性，但得益于精心构造的非线性特征，其仍能捕捉风场与飞行员操作之间的复杂依赖关系，同时保留良好的可解释性，便于后续不确定性量化与安全分析。模型结果如下

表 3.9  不同模型的性能评价指标对比

| 评价指标     | 均方误差   | 平均绝对误差 | 决定系数   | Spearman 秩相关系数 |
|----------|--------|--------|--------|----------------|
| 双支神经网络   | 0.1037 | 0.2493 | 0.3961 | 0.5993         |
| 简单线性模型   | 0.1303 | 0.2941 | 0.2409 | 0.4770         |
| 可解释性线性模型 | 0.0778 | 0.2106 | 0.5470 | 0.7473         |

由表3.9显示，引入非线性构造变量后，模型的预测精度明显提升，均方误差较神经网络相关结果提高 10% 左右，Spearman 相关系数上升至 0.74，表明新特征有效增强了模型对乱流影响的刻画能力。

此外，若聚焦于具体航班，可绘制航班降落过程中的乱流指数折线，如图3.6所示。其中上半图为航班乱流指数的折线图，下半为风场变化示意图，横轴正方向为航班飞行方向，箭头长度指代风速（为绘制效果做了等比例缩短），箭头方向为风吹往的方向，该图像可以直观对比风场动态变化与乱流指数响应之间的关联关系。




图 3.6  SHA03 某航班乱流指数及风场变化趋势

该航班在降落前半段与后半段的风场条件存在显著差异。在进近早期，风场变化幅度较小，乱流指数维持在较低水平；直至接近着陆阶段，风向发生剧烈转变

后，乱流指数也随之出现明显上升。这一现象表明，乱流指数对风场动态变化具有一定的响应敏感性，能够有效捕捉风场突变引发的湍流增强效应。

## 第四章 乱流强度区间估计

### 4.1 经典区间预测不足

在高风险运行环境（如航空、医疗或自动驾驶）中，机器学习模型的部署不仅要求其具备良好的点预测性能，更关键的是能够可靠地刻画预测结果的不确定性。在此类场景下，错误的预测可能引发灾难性后果——例如，对乱流强度的低估可能导致预警系统响应不及时，致使飞行员未及时采取措施，危及飞行安全。因此，仅提供一个“最佳估计”是远远不够的；决策者亟需知道该点估计的可信范围，即在何种置信水平下，真实值会落入所预测的区间内。

第 3.2 节所述的多元线性回归模型虽在理论上可导出预测区间，但其有效性高度依赖于一系列经典假设，例如残差需要服从独立同分布的正态分布。然而，如图 4.1 所示，模型残差在尾部区域显著偏离理论正态分位数，呈现出明显的重尾与非线性特征。这一现象说明正态性假设在实际数据中难以成立，导致基于该假设构造的传统预测区间既无法提供可靠的覆盖保证。




图 4.1 可解释性模型残差的 Q-Q 图

鉴于上述局限，本文转而采用保形预测（Conformal Prediction, CP）框架，构建一种不依赖强分布假设、且在有限样本下仍能保证覆盖率的区间估计方法，从而为高风险乱流预警提供更具鲁棒性的不确定性量化机制。

## 4.2 保形预测原理

保形预测是一种非参数化的不确定性量化框架，其核心优势在于：无需对数据做任何分布假设，且可与任意预训练模型（如神经网络、梯度提升树等）无缝集成，最终提供具有统计有效性的置信区间 [35]。

保形预测的核心流程可分为两个阶段：一是基模型的构建，为便于后续表述，作如下约定： $Y_i$  表示第  $i$  个样本的真实响应值， $X_i$  表示其对应的输入特征向量， $\hat{\mu}(\cdot)$  表示在训练集上拟合的基模型。

下面阐述第二阶段，即预测区间的构造流程。这里我们主要采用三种方法，分别为归纳式保形预测方法（Inductive Conformal Prediction, ICP），局部自适应分割共形预测方法（Locally Adaptive Split Conformal Prediction）以及共形分位数回归方法（Conformalized Quantile Regression, CQR）来构造预测区间。

在归纳式保形预测（Inductive Conformal Prediction, ICP）的标准框架下，原始数据被划分为三个互斥的子集：**训练集**  $\mathcal{S}_1$  用于拟合基础预测模型  $\hat{\mu}(\cdot)$ ；**校准集**  $\mathcal{S}_2$  用于估计模型的非一致性分数（conformity scores）并据此构造具有有限样本覆盖保证的预测区间；**测试集** 则保留用于最终评估模型的预测性能。这种划分确保了预测区间的有效性不依赖于模型假设，仅依赖于数据的交换性（exchangeability）条件。对于回归任务，传统归纳式保形预测（Inductive Conformal Prediction, ICP）通常采用绝对残差作为非一致性度量（nonconformity measure）：

$$R_i = |Y_i - \hat{\mu}(X_i)|,$$

其中： $R_i$  量化了模型在该样本上的预测偏差大小。

在校准阶段，基于校准集  $\mathcal{S}_2$ （即用于校准的样本集合），计算残差序列  $\{R_i\}_{i \in \mathcal{S}_2}$  的  $(1-\alpha)$  分位数，记为  $Q_{1-\alpha}(\{R_i\}_{i \in \mathcal{S}_2})$ ，简写为  $Q_{1-\alpha}(R, \mathcal{S}_2)$ 。随后，对新样本  $X_{n+1}$  构造对称预测区间：

$$C(X_{n+1}) = \left[ \hat{\mu}(X_{n+1}) \pm Q_{1-\alpha}(R, \mathcal{S}_2) \right], \quad (4.1)$$

其中：

- $\alpha \in (0, 1)$  为预设的显著性水平（例如  $\alpha = 0.1$  对应 90% 预测区间）；
- $Q_{1-\alpha}(R, \mathcal{J}_2)$  反映了校准集上典型预测误差的尺度；

该方法能保证有限样本下的边际覆盖（marginal coverage），然而，其生成的预测区间宽度全局恒定，无法反映输入空间中不同区域的不确定性差异，尤其在存在异方差性的数据中效率较低。

为克服这一局限，研究者提出了多种使共形预测具备局部适应能力的方法。其中，局部自适应分割共形预测（Locally Adaptive Split Conformal Prediction）是代表性工作，由 Lei 等人首次提出 [36] 并在后续研究中深入分析。该方法的关键点在于，将原始残差归一化为尺度调整后的残差（scaled residuals）：

$$R_i = \frac{|Y_i - \mu(X_i)|}{\hat{\sigma}(X_i)}, \quad i \in \mathcal{J}_2,$$

其中  $\hat{\sigma}(X_i)$  是对条件残差的估计，必须仅基于训练集  $\mathcal{J}_1$  构建，通常取为条件平均绝对偏差

$$\hat{\sigma}(X_i) \approx \mathbb{E}[|Y - \hat{\mu}(X)| \mid X = x].$$

最终，测试点  $X_{n+1}$  的预测区间为：

$$C(X_{n+1}) = [\hat{\mu}(X_{n+1}) \pm \hat{\sigma}(X_{n+1}) \cdot Q_{1-\alpha}(R, \mathcal{J}_2)]. \quad (4.2)$$

由于归一化残差在校准集上近似同分布，该方法在保持标准共形预测有限样本覆盖保证的同时，能够根据局部不确定性动态调整区间宽度——在高噪声区域自动扩展，在低噪声区域收缩，显著提升预测效率。

此外，另一种重要方法由 Romano 等人 [37] 提出，即共形分位数回归（Conformalized Quantile Regression, CQR）。该方法将分位数回归（Quantile Regression, QR）与共形预测相结合，对于一条记录，首先用已有的 QR 模型估计条件分位数  $q_{\alpha/2}(X)$  和  $q_{1-\alpha/2}(X)$ ，得到初始的预测区间，再定义非一致性度量为观测值超出初始分位数区间的程度：

$$A_i = \max\{q_{\alpha/2}(X_i) - Y_i, Y_i - q_{1-\alpha/2}(X_i)\}.$$

通过该校准分数的  $(1-\alpha)$  分位数  $Q_{1-\alpha}(\{A_i\}_{i \in \mathcal{J}_2})$  对原始分位数区间进行调整, 得到最终的预测区间为

$$C(X_{n+1}) = \left[ q_{\alpha/2}(X_{n+1}) - Q_{1-\alpha}, q_{1-\alpha/2}(X_{n+1}) + Q_{1-\alpha} \right], \quad (4.3)$$

其中  $Q_{1-\alpha} = Q_{1-\alpha}(\{A_i\}_{i \in \mathcal{J}_2})$ 。CQR 在保证覆盖的前提下进一步优化了区间长度, 适用于强异方差场景。

### 4.3 实验结果分析

本实验的第一阶段紧密衔接第 3.2 节的建模框架: 目标变量仍采用经风场校正后的飞行员操作指标 `iqr_pitch_wind` (即剔除高度对俯仰操作的影响), 自变量集合亦保持一致, 以确保结果的可比性与延续性。

在此基础上, 为系统考察不同模型结构对区间预测性能的影响, 本文选取线性回归、随机森林与多层感知机 (MLP) 三种基模型分别构建预测函数。

需要特别说明的是, 这三种方法均可实现条件分位数回归, 线性模型通过 python 中 statsmodels 中的 QuantReg 实现条件分位数回归; 随机森林采用 python 中的 quantile-forest 库提供的 RandomForestQuantileRegressor, 利用叶节点内样本的经验分布估计分位数以实现分为数回归; 神经网络则将标准损失函数替换为分位数损失 (Quantile Loss), 亦称 Pinball Loss, 其形式为

$$\mathcal{L}_\tau(y, \hat{q}_\tau) = \begin{cases} \tau(y - \hat{q}_\tau), & \text{若 } y \geq \hat{q}_\tau, \\ (1-\tau)(\hat{q}_\tau - y), & \text{若 } y < \hat{q}_\tau, \end{cases} \quad (4.4)$$

其中  $y$  表示真实观测值, 即目标变量 `iqr_pitch_wind` 的实际取值;  $\hat{q}_\tau$  表示模型在给定输入特征  $X$  下对响应变量条件  $\tau$ -分位数的预测估计;  $\tau \in (0,1)$  为目标分位水平, 用于指定所估计的分位点位置——例如,  $\tau = 0.1$  对应条件分布的 10% 分位数,  $\tau = 0.9$  对应 90% 分位数, 二者联合可构造覆盖中间 80% 概率质量的预测区间  $[\hat{q}_{0.1}, \hat{q}_{0.9}]$ 。该损失函数具有非对称性: 当预测值  $\hat{q}_\tau$  低于真实值  $y$  时, 误差被赋予权重  $\tau$ ; 当预测值高于真实值时, 误差权重为  $1-\tau$ 。这种不对称惩罚机制确保了优化过程收敛至真实的条件分位数。该方法最早由 Taylor [38] 引入神经网络用于条件密度与预测区间估计, 并已成为深度学习中实现分位数回归的标准范式。

在共形预测的实施过程中，本文特别关注局部不确定性建模的精细程度。对于 Local 共形方法，我们采用一种数据驱动的策略：在获得初始点预测模型  $\hat{\mu}(X_i)$  后，以训练集上的绝对残差  $|Y_i - \hat{\mu}(X_i)|$  作为响应变量，原始特征  $X_i$  作为输入，额外训练一个与基模型同构的辅助模型来估计局部尺度  $\hat{\sigma}(X_i)$ 。尽管该策略增加了计算开销，且其效果依赖于  $\hat{\mu}$  的准确性，但能更有效地捕捉输入相关的异方差结构，从而提升预测区间的适应性。所有模型均在 10 个不同的随机种子下重复训练与评估，以控制随机性带来的波动。

为全面衡量所生成预测区间的质量，本文采用两个核心评价指标：覆盖率 (Coverage Rate) 与平均区间宽度 (Average Prediction Interval Width)。覆盖率定义为测试集中真实响应值落入对应预测区间内的样本比例，其理想值应不低于预设的置信水平（如 90%），反映预测区间的统计有效性；平均区间宽度则衡量所有预测区间的平均长度，体现预测的精确性——在保证目标覆盖率的前提下，宽度越小，说明不确定性量化越紧致、信息量越高。这两个指标共同构成对预测区间“有效性”与“效率”的综合评估，是共形预测领域广泛采纳的标准准则。最终结果以 10 次重复实验的均值形式报告。

表 4.1 不同方法与基学习器的平均覆盖率及平均区间宽度对比

| 方法           | 基学习器        | 平均覆盖率         | 平均区间宽度      |
|--------------|-------------|---------------|-------------|
| CQR          | 神经网络        | 90.25%        | 1.21        |
| CQR          | 随机森林        | 90.06%        | 0.83        |
| <b>CQR</b>   | <b>线性模型</b> | <b>90.13%</b> | <b>0.88</b> |
| Split        | 神经网络        | 90.20%        | 1.01        |
| Split        | 随机森林        | 90.16%        | 0.82        |
| Split        | 线性模型        | 89.10%        | 0.88        |
| <b>Local</b> | <b>随机森林</b> | <b>90.10%</b> | <b>0.81</b> |
| Local        | 线性模型        | 90.16%        | 0.88        |

由表 4.1 可见，绝大多数方法在不同基学习器下均实现了接近或略高于 90% 的平均覆盖率，整体满足统计有效性要求。然而，预测区间的实用价值更取决于其信息效率——即在保证覆盖的前提下尽可能窄的宽度。

首先，基于神经网络的方法普遍表现出较大的区间宽度，尤其 **Local + 神经网络** 组合因残差建模失效而完全不可用，尽管其覆盖率尚可（表中未列出，但先前实验显示其宽度高达数千量级），反映出深度模型在估计局部尺度  $\hat{\sigma}(X_i)$  时极易过拟合训练残差，导致不确定性被严重高估。即便在 **CQR** 和 **Split** 框架下，神经网络的区间宽度（分别为 1.21 和 1.01）也显著宽于其他基模型，说明其在本任务中未能有效提升精度，反而牺牲了效率。

其次，对于线性模型，三种共形策略（**CQR**、**Split**、**Local**）所得结果高度相似：覆盖率均在 89.10%–90.16% 之间，区间宽度稳定在 0.88 左右。这表明在线性假设近似成立的场景下，不同不确定性量化框架的性能差异有限。然而，**CQR** 方法的优势在于能生成输入依赖的非对称区间，而 **Split** 和 **Local** 在此任务中因模型表达能力受限，难以体现局部适应性。因此，尽管数值接近，**CQR + 线性模型** 仍因其理论完备性与可解释性被保留为线性基准。

最后，**Local + 随机森林** 组合展现出显著优势：其平均区间宽度仅为 0.81，为全表最窄，同时覆盖率达 90.10%，完美兼顾有效性与效率。这说明随机森林能够有效捕捉特征与残差之间的非线性关系，**Local** 框架成功将其转化为精细的局部尺度估计，从而在不牺牲覆盖的前提下大幅压缩预测区间，提供更具操作价值的风险边界。

综上，本文在后续可视化分析中将重点对比 **CQR + 线性模型**（代表可解释、稳定的线性基准）与 **Local + 随机森林**（代表高效、自适应的非线性方案）。首先选取测试集中 `iqr_pitch_wind` 跨度较大的航班样本，直观展示两种方法在实际飞行场景中的区间预测行为差异。




图 4.2 线性模型 `cqr` 部分航班预测区间示例




图 4.3 随机森林 local 部分航班预测区间示例

由图4.2与图4.3的结果可知，尽管线性模型 CQR 的预测区间相对稳定，但在部分样本处表现出轻微偏宽趋势，而随机森林 local 则展现出更强的适应性，在一些点处预测区间更窄，更应用中符合相关需要。

部分航班的图像揭示了一个问题，在极端高值与极端低值上，区间估计更容易发生偏离问题。但在这个问题上，我们本身更关注高风险航班，即 iqr\_pitch\_wind 较大的航班的数据预测情况。同时考虑到降落的最终阶段的重要性，这一部分的预测效果也应得到管制。因此我们对高度与 iqr\_pitch\_wind 分别进行等频分箱处理，考虑在边界上的区间的预测情况。




图 4.4 线性模型 cqr 分箱下的准确率

显然，两种方法在极端情况下的覆盖率均表现出一定程度的下降趋势。具体而言，在高 iqr\_pitch\_wind（即乱流影响较强）和低 Height（即接近地面高度）的区域，预测区间对真实值的覆盖能力有所减弱，这表明模型在边界条件下的不确

定性估计面临挑战。但对比两类方法可见，随机森林 local 方法在高度分箱内能维持约 0.85 以上的覆盖率，表现出较强的鲁棒性；而线性模型 CQR 在相同数据下覆盖率降至 0.75 以下，其覆盖性能明显弱于随机森林 local。




图 4.5 随机森林 local 分箱下的准确率

第五章 机场整体乱流指数分布

5.1 机场预警研究

在上面的相关工作中，针对航班里的每一秒数据，能够依据相关模型，给出相应应的乱流指数与其预测区间，然而在优化航班运营安全的过程中，针对乱流指数的应用价值依赖于合理的参照基准。因此，在实际使用过程中，应该从机场整体角度进行相关分析，尝试建立一个动态、稳健且具有代表性的“正常范围”参考框架，用于识别异常事件并支持运行决策。

为了实现这一目标，需要先考察整体分布情况，绘制 SHA03 的 A320 航班的乱流指数分布图，如图5.1所示，图线存在明显右偏现象。




图 5.1 3 月 A320 航班乱流指数整体分布情况

一种直观的策略是汇总一段时间内的历史乱流指数，直接计算其 90% 分位数与 10% 分位数作为全局统一的上下预警阈值。然而，该方法忽略了乱流强度往往具有显著的日周期性特征——例如在午后对流活跃时段，乱流指数普遍高于夜间或清晨。若采用静态阈值，可能导致高发时段预警灵敏度不足，而在低发时段产生过多虚警，从而削弱整体预警效能。

为此，本文提出一种基于时间窗口的动态阈值构建方法：首先，选取一段代表性历史数据（本文以 3 月全月数据为例）；随后，将每日运行时间划分为若干固定长度的时间窗口（本文采用 10 分钟为一个窗口），并对每个窗口内对应的历史乱流




图 5.2 乱流指数预警线示例图

指数进行分组统计；在此基础上，针对每个时间窗口独立计算其 95% 分位数作为该时段的动态上限阈值（下限可类似设定或根据需求调整）；最终，形成一组与一天中不同时段一一对应的预警区间，从而实现对乱流风险的精细化、自适应监测。

最终结果如图5.2所示，这套阈值能适应不同时段的大气稳定性特征，从而提升预警系统的整体准确性与实用性。

随着时间推移，历史数据的时间段也需要随着季节与调度变化进行更新。基于图5.2，进一步引入区间估计相关结果，在时间分组中计算上界的 90 分位数与下界的 10 分位数作为正常范围的上界与下界，以阴影部分标出作为正常波动区域。这一步骤的结果展示在图5.3中。




图 5.3 虹桥机场 3 月航班乱流指数安全范围

当连续多日出现大批次航班的乱流指数偏离正常范围（无论是持续偏高还是偏低），则表明当前参考图所依赖的历史数据窗口可能已无法准确反映最新的风场

特征。此时，应及时更新图像所覆盖的时间范围，重新计算基准区间以及预警线，以确保监控系统的敏感性与适应性。

5.2  风险持续性分析

在前述按时间窗口对乱流指数的统计分析基础上，一个更具操作意义的问题亟待回答：高风险乱流事件是否在日尺度上呈现持续性？换言之，若某日清晨出现显著乱流扰动，这种异常状态是否会延续至后续时段？若存在此类持续性特征，则意味着当日整体运行环境可能处于不稳定状态，进而为动态调度、机组预警和流量管理提供关键决策依据。

为探究这一问题，本文选取 3 月 10 日作为检验日，以该月前 9 天（3 月 1 日至 9 日）的历史航班乱流指数数据构建基准分布。

| HOURL | 总航班数 | 正常 | 关注 | 危险 |
|-------|------|----|----|----|
| 8     | 3    | 1  | 1  | 1  |
| 9     | 3    | 1  | 0  | 2  |
| 10    | 4    | 0  | 2  | 2  |
| 11    | 6    | 2  | 1  | 3  |
| 12    | 2    | 1  | 0  | 1  |
| 13    | 3    | 3  | 0  | 0  |
| 14    | 3    | 0  | 1  | 2  |
| 15    | 6    | 3  | 2  | 1  |
| 16    | 2    | 1  | 1  | 0  |
| 17    | 5    | 3  | 1  | 1  |
| 18    | 5    | 0  | 1  | 4  |
| 19    | 4    | 0  | 0  | 4  |
| 20    | 5    | 1  | 0  | 4  |
| 21    | 5    | 2  | 1  | 2  |
| 22    | 7    | 7  | 0  | 0  |
| 23    | 8    | 7  | 1  | 0  |

表 5.1  3 月 10 日各小时航班状态统计

首先将历史数据按 30 分钟为一个时间窗口进行划分，并在每个窗口内计算乱

流指数的 95% 分位数，作为该时段对应的预警上限，从而形成覆盖全天的时间区域化预警线。随后，对 3 月 10 日的所有航班逐秒进行回溯验证：若某航班在其运行过程中任意时刻的乱流指数未超过对应时间窗口的警戒值，则标记为正常航班；若出现至少一个超标点，则记为关注航班；进一步地，若某一关注航班在连续 8 秒内均处于预警状态（即乱流指数持续高于阈值），则被判定为危险航班。最终，按小时粒度汇总三类航班（正常、关注、危险）的数量与分布，以分析乱流风险在一天中的演化规律及其与时间窗口预警策略的匹配程度。

分析结果如表 5.1 所示。值得注意的是，傍晚时段（18:00–20:00）危险航班高度集中，几乎所有航班均被判定为危险，表明该时段存在系统性强乱流扰动。相比之下，夜间（22:00 后）风险显著降低，全部航班恢复至正常状态，反映出大气边界层趋于稳定。此外，关注与危险航班在 10:00–15:00 之间呈交替出现态势，暗示该时段乱流具有间歇变化特征，可能与日间热力对流发展及城市热岛环流耦合有关。

综上，该分析不仅验证了乱流风险在日内具有一定非均匀性和潜在持续性，也为构建“基于实时风险等级的弹性航班调度机制”提供了实证支持——例如，在检测到早间出现关注或危险航班后，可提前对后续时段实施容量调整或航路偏置策略，从而提升运营安全程度与效率。

## 第六章 总结与展望

### 6.1 研究工作总结

本文围绕航空安全领域中的进近阶段乱流风险评估问题，目标为构建一种融合 QAR 多维飞行参数、显式建模飞行员操作响应、兼具高预测性能与强可解释性、并能提供统计可靠预测区间的乱流评估新范式。主要工作与贡献总结如下：

构建了融合高度效应分离的乱流指数：针对现有研究中响应变量易受飞行高度干扰的问题，本文在前人工作的基础上，创新性地采用双分支神经网络架构。该模型将飞行高度与其他风场变量分别建模，有效剥离了高度对飞行员操作幅度的影响，从而提取出更能纯粹反映外部风场乱流强度的指标。实验结果表明，该方法在拟合精度和排序一致性上均优于传统的半参数模型。

建立了高精度且物理意义明确的可解释模型：为克服神经网络“黑箱”特性带来的应用障碍，本文并未直接使用其输出作为最终模型。而是以神经网络分离出的高度无关残差作为新的响应变量，通过特征工程（如引入风向-航向夹角的三角函数分量）和基于 SHAP 值的重要性筛选，构建了一个性能优越的线性回归模型。该模型不仅显著提升了预测精度（Spearman 相关系数达 0.7473），而且其线性结构和物理衍生变量使得模型决策过程清晰透明，便于在实际运行中进行解读与验证。

实现了具有统计保证的乱流强度区间预测：考虑到航空安全决策对可靠性的极高要求，本文引入了多种保形预测法，并对结果进行对比，为乱流指数提供了在不同置信水平下的预测区间。该类方法不依赖于强分布假设，能够有效处理模型残差的异方差性，为风险分级预警和空管决策提供了坚实的统计学依据。

开展了机场尺度的时空分布与预警应用探索：在单航班乱流指数的基础上，本文进一步从机场运行管理视角出发，对多航班数据进行了聚合分析。研究发现，乱流高风险事件在“日间维度”上的差异远大于“日内时段”维度，表明单日的整体气象环境是影响风险的关键因素。基于此，本文提出了动态更新的“正常范围”参考框架和预警线，为机场实现主动式、数据驱动的安全监控与预警提供了可行方案。

## 6.2 研究不足与未来展望

尽管本研究在基于飞行员操作响应的低空乱流风险评估方面取得了一系列有意义的成果，构建了从风场特征工程、不确定性量化到可解释建模的完整技术链条，但仍存在若干值得深入探讨的局限性，这些局限也为后续研究提供了明确而富有潜力的方向。

第一，数据源的单一性约束了当前研究的广度与深度。本文所依赖的数据来源于飞机快速存取记录器（QAR），这类数据虽能高频率、高保真地记录飞行过程中机体的实际动态响应，从而间接反映外部风扰的强度与特性，但其本质仍属于“效应观测”而非“原因观测”。换言之，QAR 数据捕捉的是飞机在湍流作用下的结果表现，却无法直接揭示大气湍流本身的物理结构、能量谱分布或空间演化过程。这种间接性在一定程度上限制了模型对乱流机理的深层刻画能力。

第二，模型泛化能力的验证范围尚显局限。当前实验仅基于特定机场（SHA）及单一机型（A320 系列）的历史 QAR 数据开展训练与评估，虽然在该场景下表现出良好的预测性能与区间覆盖特性，但其在更广泛运行环境中的适应性仍未得到充分检验。不同地理区域（如高原、沿海、内陆）、不同气候条件（如季风期、冬季强对流季节）以及不同机型（如宽体客机、支线飞机）在气动特性、飞控逻辑与操作规范上均存在显著差异，这些因素可能对模型的外推能力构成挑战。

第三，本文将飞行员操作作为乱流强度的代理信号，虽已通过加性模型结构对飞行高度的影响进行分离，并借助神经网络捕捉风场变量间的非线性关系，但整体建模框架仍相对简化。一方面，当前模型未充分考虑风场特征与飞行高度之间可能存在的交互或混合效应——例如，相同风切变在不同高度层对飞机响应的影响可能存在显著差异，而现有结构难以有效刻画此类耦合机制。

第四，实时预警系统的工程化落地仍处于初步阶段。本研究目前侧重于离线的事后分析与风险回溯，虽在方法论层面提出了一种面向主动预警的相关策略，并且具备生成统计有效预测区间的理论保障，但距离实际运行场景中的近实时应用尚有差距。主要瓶颈在于算法的计算效率、延迟容忍度与系统集成能力，在标准服务器环境下完成单航班推理可能耗时数秒，难以满足进近阶段“分钟级甚至秒级”

决策支持的需求。

针对上述局限，未来工作可从以下四个方面展开深入探索，以推动低空乱流风险评估方法向更高精度、更强鲁棒性与更广适用性演进。

第一，推动多源异构数据融合，突破单一 QAR 数据的观测瓶颈。在保留飞机响应高保真记录优势的基础上，系统引入气象雷达对风切变的遥感反演、激光雷达 (LiDAR) 对低空风场剖面的精细探测，以及高时空分辨率的数值天气预报 (NWP) 再分析产品。通过构建“大气扰动直接感知 + 飞机动态响应验证”的联合建模框架，有望实现从间接代理推断向物理机制驱动的模式升级，从而提升对湍流结构、强度与演化过程的刻画能力。

第二，拓展模型验证场景，强化泛化能力。未来应收集覆盖多机场（如高原机场 LXA、沿海机场 CAN、内陆枢纽 CTU）、多气候带（季风区、干旱区、寒温带）及多机型（如 B787 宽体机、ARJ21 支线客机）的大规模 QAR 数据集，开展跨域评估实验。在此基础上，可引入迁移学习或域自适应 (Domain Adaptation) 技术，使模型能够有效应对地理、气候与机型带来的分布偏移，提升其在真实复杂运行环境中的适应性与可靠性。

第三，深化模型结构设计，增强对复杂耦合关系的表达能力。一方面，可在现有加性模型基础上引入风场特征与飞行高度的交互项（如  $WIN\_SPD \times Altitude$  或分层非线性变换），以显式建模不同高度层下风扰对飞机响应的差异化影响；另一方面，可探索混合建模范式，例如将神经网络嵌入广义加性模型 (GAM-NN) 或采用注意力机制动态加权环境与状态变量，从而更灵活地捕捉高维非线性与局部敏感性。

第四，加速算法工程化落地，迈向近实时预警应用。需重点优化共形预测全流程的计算效率：包括简化高阶特征生成逻辑、采用轻量化基模型（如稀疏线性模型或小型 MLP）、设计增量式校准策略以避免重复计算，并探索 GPU 加速或边缘部署方案。最终目标是将本框架集成至机场塔台辅助决策系统或航空公司运行控制中心 (AOC)，实现对进近航班乱流风险的秒级监测、动态区间输出与可视化告警，真正支撑“预测—预警—干预”一体化的安全闭环。

## 参考文献

- [1] International Air Transport Association. 2024 Safety Report[R]. Geneva, Switzerland : International Air Transport Association (IATA), 2024.
- [2] 中国民用航空局. 2024 年民航行业发展统计公报 [R]. 北京 : 中国民用航空局, 2025.
- [3] International Civil Aviation Organization. Safety Report 2023: Global Aviation Safety Plan (G ASP) Indicators[R]. Montreal, Canada : International Civil Aviation Organization (ICAO), 2024.
- [4] Boeing Commercial Airplanes. Statistical Summary of Commercial Jet Airplane Accidents: Worldwide Operations 1959–2022[R/OL]. Seattle, WA : Boeing, 2023.  
[https://www.boeing.com/content/dam/boeing/boeingdotcom/commercial/airports/acaps/accident\\_summary.pdf](https://www.boeing.com/content/dam/boeing/boeingdotcom/commercial/airports/acaps/accident_summary.pdf).
- [5] 蔡靖, 周宁, 王岩, et al. 飞机冲偏出跑道事故统计分析及后果预测研究 [J]. 中国民航大学学报, 2025, 43(05) : 37–43.
- [6] ZHANG H, WU S, WANG Q, et al. Airport low-level wind shear lidar observation at Beijing Capital International Airport[J]. Infrared Physics & Technology, 2019, 96 : 113–122.
- [7] 李乃方. 机载多普勒天气雷达的空中应用研究 [J]. 中国高新区, 2017(23) : 18.
- [8] 杜海浪. 多普勒测风激光雷达在航空气象中的应用进展 [J]. 激光与光电子学进展, 2024, 61(24) : 25–37.
- [9] YUAN J, SU L, XIA H, et al. Microburst, windshear, gust front, and vortex detection in mega airport using a single coherent Doppler wind lidar[J]. Remote Sensing, 2022, 14(7) : 1626.

- [10] CAI J, ZHANG Y, DOVIAK R J, et al. Diagnosis and classification of typhoon-associated low-altitude turbulence using HKO-TDWR radar observations and machine learning[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(6): 3633–3648.
- [11] CHAN P, HON K, SHIN D. Combined use of headwind ramps and gradients based on LIDAR data in the alerting of low-level windshear/turbulence[J/OL]. Meteorologische Zeitschrift, 2011, 20: 661–670.  
<http://dx.doi.org/10.1127/0941-2948/2011/0242>.
- [12] ZHAO S, YANG C, SHAN Y, et al. Identification and Analysis of Wind Shear Within the Transiting Frontal System at Xining International Airport Using Lidar[J]. Remote Sensing, 2025, 17(5): 732.
- [13] 贺刚, 陈行娟, 卢飞, et al. QAR 数据的应用与研究进展 [J/OL]. 科技风, 2024(20): 164–166.  
<http://dx.doi.org/10.19392/j.cnki.1671-7341.202420055>.
- [14] WANG X, WANG Y, YU L, et al. Statistical Analysis and Prevention of Low-level Wind Shear Warning Events[C] // 2021 IEEE 3rd International Conference on Civil Aviation Safety and Information Technology (ICCASIT). 2021: 408–411.
- [15] ITO K, OHBA H, MIZUNO S. Low-level turbulence risk assessment and visualization using temporal rate of change of headwind of an aircraft[J]. Journal of Big Data, 2024, 11(1): 158.
- [16] KIM S-H, KIM J, KIM J-H, et al. Characteristics of the derived energy dissipation rate using the 1-Hz commercial aircraft Quick Access Recorder (QAR) data[J]. Atmospheric Measurement Techniques Discussions, 2021, 2021: 1–36.
- [17] HUANG R, SUN H, WU C, et al. Estimating eddy dissipation rate with QAR flight big data[J]. Applied Sciences, 2019, 9(23): 5192.

- [18] ZHUANG Z, LIN K, ZHANG H, et al. Detection of turbulence anomalies using a symbolic classifier algorithm in airborne quick access record (QAR) data analysis[J]. *Advances in Atmospheric Sciences*, 2024, 41(7): 1438–1449.
- [19] MIZUNO S, OHBA H, ITO K. Machine learning-based turbulence-risk prediction method for the safe operation of aircrafts[J]. *Journal of Big Data*, 2022, 9(1): 29.
- [20] HON K K, NG C W, CHAN P W. Machine learning based multi-index prediction of aviation turbulence over the Asia-Pacific[J]. *Machine Learning with Applications*, 2020, 2: 100008.
- [21] KHATTAK A, ZHANG J, CHAN P-W, et al. Aviation Safety at the Brink: Unveiling the Hidden Dangers of Wind-Shear-Related Aircraft-Missed Approaches[J]. *Aerospace*, 2025, 12(2): 126.
- [22] KIM J-H, CHAN W N, SRIDHAR B, et al. Combined winds and turbulence prediction system for automated air-traffic management applications[J]. *Journal of Applied Meteorology and Climatology*, 2015, 54(4): 766–784.
- [23] HAGHIGHI A N, NOLIN R D, PUNDSACK G D, et al. High-altitude atmospheric turbulence and infrasound measurements using a balloon-launched small uncrewed aircraft system[J]. *EGUsphere*, 2023, 2023: 1–30.
- [24] KHAROUFAH H, MURRAY J, BAXTER G, et al. A review of human factors causations in commercial air transport accidents and incidents: From to 2000–2016[J]. *Progress in Aerospace Sciences*, 2018, 99: 1–13.
- [25] GUO Y, SUN Y, HE Y, et al. Deep-learning-based model for accident-type prediction during approach and landing[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2022, 59(1): 472–482.

- [26] CHEN N, LI J, MAN Y. Using SHELL and risk matrix method in identifying the hazards of general aviation flight approach and landing[C] // 2021 6th International Conference on Transportation Information and Safety (ICTIS). 2021 : 704–712.
- [27] YANG L, CAO L, WANG Z, et al. Evaluation of Pilots' Flight Control Performance under Wind shear Scenario based on Big Data[C] // 2025 8th International Conference on Artificial Intelligence and Big Data (ICAIBD). 2025 : 26–31.
- [28] QINBIAO L, CHUN-HSIEN C, KAM K, et al. Single-pilot operations in commercial flight: Effects on neural activity and visual behaviour under abnormalities and emergencies[J]. Chinese Journal of Aeronautics, 2024, 37(8) : 277–292.
- [29] LI X, QIAN Y, CHEN H, et al. An unsupervised learning approach for analyzing unsafe pilot operations based on flight data[J]. Applied Sciences, 2022, 12(24) : 12789.
- [30] LI C, SUN R, PAN X. Takeoff runway overrun risk assessment in aviation safety based on human pilot behavioral characteristics from real flight data[J]. Safety science, 2023, 158 : 105992.
- [31] 中国民用航空局飞行标准司. 飞行品质监控 (FOQA) 实施与管理 [S]. 2015.
- [32] 徐沐彦. 基于 QAR 数据的飞机进近阶段乱流指数构建 [D]. 上海 : 华东师范大学, 2025.
- [33] LUNDBERG S M, LEE S-I. A unified approach to interpreting model predictions[J]. Advances in neural information processing systems, 2017, 30.
- [34] LUNDBERG S M, ERION G G, LEE S-I. Consistent individualized feature attribution for tree ensembles[J]. arXiv preprint arXiv:1802.03888, 2018.
- [35] SHAFER G, VOVK V. A tutorial on conformal prediction[J]. Journal of Machine Learning Research, 2008, 9(3) : 371–421.

- [36] LEI J, G'SELL M, RINALDO A, et al. Distribution-free predictive inference for regression[J]. Journal of the American Statistical Association, 2018, 113(523) : 1094 – 1111.
- [37] ROMANO Y, PATTERSON E, CANDES E. Conformalized quantile regression[J]. Advances in neural information processing systems, 2019, 32.
- [38] TAYLOR J W. A Quantile Regression Neural Network Approach to Estimating the Conditional Density of Forecast Errors[J]. Journal of Forecasting, 2000, 19(3) : 235 – 246.

## 致 谢

时光飞逝，两年的研究生求学生涯已近尾声。回望这段充实而富有挑战的旅程，有过探索未知的困惑，也有豁然开朗的欣喜；有挑灯夜战的坚持，更有收获成长的欣慰。值此论文付梓之际，谨向所有关心、支持和帮助过我的师长、同窗与亲友致以最诚挚的谢意。

首先，我要向我的导师钟琰致以最崇高的敬意和最深切的感激。从论文的选题、框架搭建到最终的修改定稿，每一步都凝聚着您大量的心血与智慧。您严谨求实的治学态度、敏锐深邃的学术洞察力以及精益求精的科研精神，不仅为我的研究工作指明了方向，更深刻地塑造了我的思维方式与学术品格。能成为您的学生，是我研究生阶段最大的荣幸。

衷心感谢课题组的同门杨骏宝，以及我的舍友盛博恒、沈周翔、曾莫恒。你们是我求学路上最亲密的伙伴与同行者。无论是实验室里并肩攻关、热烈讨论的日夜，还是宿舍中畅谈理想、互相打气的时光，都构成了我研究生生活最温暖、最鲜活的底色。感谢你们在学术上的切磋互助，在生活中的包容关照，是你们让这段旅程充满欢笑、支持与归属感。

同时，诚挚感谢江苏银行为我提供了宝贵的实习机会。在此期间，我得以将所学理论知识应用于实践，极大地拓宽了视野，提升了专业能力。特别感谢我的实习导师及部门同事们的悉心指导与信任支持，你们的实践经验与行业洞见不仅丰富了我的研究素材，也让我对专业领域有了更真切的理解。

最后，我要将最深沉的爱意献给我的家人。是你们无条件的爱与默默付出，成为我一路前行最坚实的后盾，赋予我不断探索与成长的勇气。

谨以此文，致敬青春，致敬所有照亮我前行之路的人。未来的路，我将带着这份感恩，继续砥砺前行。

徐宇航

2026年5月7日

